



Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης
Πολυτεχνική Σχολή
Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Τομέας Ηλεκτρονικής

ΑΥΤΟΜΑΤΗ ΠΑΡΑΓΩΓΗ ΚΩΔΙΚΑ ΓΙΑ
ΕΠΙΤΑΧΥΝΣΗ ΥΠΟΛΟΓΙΣΜΩΝ ΠΡΟΤΥΠΩΝ ΣΕ
ΚΑΡΤΕΣ ΓΡΑΦΙΚΩΝ ΜΕ JULIA

Διπλωματική Εργασία
Κωνσταντίνος Χατζηαντωνίου

Επιβλέπων: Νικόλαος Πιτσιάνης
Καθηγητής Α.Π.Θ. 15 Δεκεμβρίου 2020

Περίληψη

Η Julia είναι μια δυναμική γλώσσα, υψηλού επιπέδου, που επικεντρώνεται σε αριθμητικούς υπολογισμούς. Η υψηλή της απόδοση την κάνει ιδανικό υποψήφιο για επιστημονικές εφαρμογές που απαιτούν ταχύτητα, ενώ η δυναμικότητά της διευκολύνει την ανάλυση και προτυποποίηση ιδεών. Με την πρόσφατη υποστήριξη για κάρτες γραφικών, μπαίνει πιο δυναμικά στον κόσμο των υπολογισμών υψηλής απόδοσης (High Performance Computing). Οι υπολογισμοί προτύπων αποτελούν επαναληπτικές διαδικασίες όπου ανανεώνουν τα δεδομένα, συναρτήσεϊ των γειτονικών τους στοιχείων. Εφαρμόζονται σε ένα μεγάλο αριθμό από πεδία, όπως μηχανική ρευστών, επεξεργασία εικόνας, εφαρμογές βιοϊατρικής και επίλυση μερικών διαφορικών εξισώσεων. Λόγω του πλήθους των εφαρμογών, αλλά και της ποικιλίας των επιστημονικών πεδίων τους, αποτελεί επιτακτική ανάγκη όχι μόνο η επιτάχυνση αλλά και η αυτόματη παραγωγή κώδικα για υπολογισμό προτύπων. Στην παρούσα διπλωματική, η Julia λύνει και τα δύο (2) προβλήματα. Με το υψηλό της επίπεδο και τη δυναμικότητά της δημιουργείται μια πλατφόρμα εύχρηστη για έρευνα σε κάθε κλάδο, ενώ με την υψηλή της απόδοση επιτυγχάνονται σημαντικές επιταχύνσεις. Επιπλέον, υλοποιούνται δύο νέοι τρόποι επιτάχυνσης υπολογισμών προτύπων, μια διαφορετική ομαδοποίηση βημάτων χρόνου και υπολογισμός προτύπου στο πεδίο της συχνότητας. Τέλος, παρατίθενται αναλυτικά αποτελέσματα που επιβεβαιώνουν την αποτελεσματικότητα των μεθόδων, την υψηλή απόδοση της και την ποιότητα κώδικα που επιφέρει η χρήση της Julia.

Ευχαριστίες

Ευχαριστώ τον καθηγητή μου, κύριο Νίκο Πιτσιάνη για το ιδιαίτερα ενδιαφέρον θέμα, την πολύτιμη βοήθειά του και την καθοδήγησή του στην εκπόνηση της διπλωματικής εργασίας μου. Ευχαριστώ επίσης τους γονείς μου για τη στήριξή τους κατά τη διάρκεια της διπλωματικής μου αλλά και των σπουδών μου. Ειδικότερα, ευχαριστώ τη μητέρα μου για τη φιλολογική επιμέλεια των κειμένων της εργασίας μου.

Περιεχόμενα

1	Εισαγωγή	7
1.1	Εισαγωγή στις κάρτες γραφικών	7
1.2	Εισαγωγή στην Julia	7
1.3	Κίνητρο και στόχος της διπλωματικής εργασίας	8
1.4	Οργάνωση Κειμένου	8
2	Βασικές Έννοιες	9
2.1	CUDA και κάρτες γραφικών NVIDIA	9
2.1.1	Μοντέλο Προγραμματισμού	9
2.1.2	Ιεραρχία Μνήμης	10
2.1.3	Αρχιτεκτονική Υλικού	10
2.1.4	Βελτίωση Απόδοσης	10
2.1.5	Επιπλέον χαρακτηριστικά	12
2.2	Julia	13
2.2.1	Μεταπρογραμματισμός και Ενδοσκοπήση	13
2.2.2	LLVM και Δυναμική Μεταγλώττιση	13
2.2.3	CUDA.jl	13
3	Μελέτες Περιπτώσεων	15
3.1	Εισαγωγή	15
3.2	Μελέτη 1 - Κοντινότερος Γείτονας σε πλέγμα	15
3.2.1	Περιγραφή Προβλήματος	15
3.2.2	Περιγραφή Υλοποίησης	15
3.2.3	Ποιότητα Κώδικα	16
3.2.4	Επίδοση και Μετρικές	18
3.3	Μελέτη 2 - Αριθμός Τριγώνων σε Γράφο	22
3.3.1	Περιγραφή Υλοποίησης	23
3.3.2	Ποιότητα Κώδικα	23
3.3.3	Απόδοση και Μετρικές	24
3.4	Σχόλια	26
4	Υπολογισμοί Προτύπων	28
4.1	Ορισμός του προτύπου	28
4.2	Πρότυπα σε κάρτες γραφικών	29
4.3	Βελτιστοποίηση	29
4.3.1	Μοτίβο Προσπέλασης Μνήμης	29
4.3.2	Αλλαγή Μεγέθους Πίνακα	30
4.3.3	Ομαδοποίηση στον χρόνο	30

4.3.4	Αυτόματη Ρύθμιση	32
4.3.5	Αυτόματη Παραγωγή Κώδικα	33
5	Πλατφόρμα για παραγωγή κώδικα προτύπου και εκτέλεση σε πολλαπλές κάρτες γραφικών	34
5.1	Κίνητρο	34
5.2	Σκοπός και Περιγραφή της πλατφόρμας	34
5.3	Δομή της πλατφόρμας	35
5.4	Βελτιστοποιήσεις	38
5.4.1	Καθολική και Μεριζόμενη μνήμη	38
5.4.2	Ξετύλιγμα βρόγχων επανάληψης	38
5.4.3	Ομαδοποίηση Βημάτων Χρόνου	39
5.5	Πολλαπλές Κάρτες Γραφικών	40
5.6	Υπολογισμός προτύπου με FFT	41
6	Άποτελέσματα	43
6.1	Αποτελέσματα απόδοσης	43
6.1.1	Ομαδοποίηση στον χρόνο	44
6.1.2	Πολλαπλές Κάρτες Γραφικών	49
6.1.3	Υπολογισμός προτύπων με FFT	50
6.2	Ποιότητα Κώδικα	54
6.2.1	Δημιουργία της πλατφόρμας	54
6.2.2	Μία Κάρτα Γραφικών	55
6.2.3	Πολλαπλές κάρτες γραφικών	56
7	Συμπεράσματα και Μελλοντική Έρευνα	58
7.1	Συζήτηση για υπολογισμούς προτύπων	58
7.1.1	Συμπεράσματα	58
7.1.2	Μελλοντική Έρευνα	59
7.2	Συζήτηση για την Julia	59
7.2.1	Συμπεράσματα	59
7.2.2	Μελλοντική Έρευνα	60
8	Παράρτημα	62

Κατάλογος Σχημάτων

2.1 Ομαδοποιημένη πρόσβαση στην καθολική μνήμη	11
2.2 Οπτικοποίηση τραπεζών μνήμης στη μεριζόμενη μνήμη	12
3.1 Σύγκριση Julia με C για simple GridKnn	18
3.2 Σύγκριση Julia με C για simple GridKnn	18
3.3 Σύγκριση Julia με C για GridKnn with Skip	19
3.4 Σύγκριση Julia με C για GridKnn with Skip	19
3.5 Χρήση καταχωρητών για GridKNN.	20
3.6 Αξιοποίηση πόρων κάρτας γραφικών.	21
3.7 Julia - Επιτάχυνση με τη χρήση @view.	22
3.8 Julia - Επιτάχυνση με τη χρήση @view.	22
3.9 C - Επιτάχυνση με δήλωση τύπων.	24
3.10 C - Επιτάχυνση με δήλωση τύπων.	25
3.11 Χρήση καταχωρητών.	25
3.12 Julia - Επιτάχυνση με δήλωση τύπων.	26
4.1 Οπτικοποίηση προτύπου για ένα στοιχείο και βήμα χρόνου για την δισδι- άστατη διακριτή Λαπλασιανή.	29
4.2 Ένα βήμα χρόνου για το κεντρικό στοιχείο. Δε χρειάζονται επιπλέον στοι- χεία.	31
4.3 Δύο βήματα χρόνου για το κεντρικό στοιχείο. Χρειάζονται επιπλέον στοι- χεία, το οποία όμως έχουν ήδη διαβαστεί στο κανονικό στεφάνι(halo). . . .	31
4.4 Δύο βήματα χρόνου για το κεντρικό στοιχείο. Χρειάζονται επιπλέον στοι- χεία για το στεφάνι και απαιτούνται περιττές πράξεις για την ανανέωσή του.	31
5.1 Γενική εικόνα της αρχιτεκτονικής.	36
5.2 Δισδιάστατο πρότυπο αστέρι με ομαδοποίηση βημάτων χρόνου.	40
5.3 Οπτικοποίηση διάσπασης δεδομένων σε πολλαπλές κάρτες γραφικών. . .	41
6.1 Σύγκριση της Julia με τη C για πρότυπο-αστέρι.	43
6.2 Σύγκριση της Julia με τη C για πρότυπο-αστέρι.	44
6.3 3 τύποι προτύπου με διαφορετικές πυκνότητες. 1) Άθροισμα ροών 2) Αστέρι 3) Πυκνό	45
6.4 Επιτάχυνση με ομαδοποίηση βημάτων χρόνου.	45
6.5 Επιτάχυνση με ομαδοποίηση βημάτων χρόνου.	46
6.6 Meng κ.α. [1] Ομαδοποίηση βημάτων χρόνου για διάφορα μεγέθη δεδο- μένων εισόδου. Το ύψος του τραπεζίου συμβολίζει τον αριθμό βημάτων χρόνου που ομαδοποιούνται.	47

6.7	Holewinski κ.α. [2] Απόδοση σε διαφορετικές κάρτες γραφικών, με και χωρίς ομαδοποίηση βημάτων χρόνου. Μόνο το Jacobi 3D είναι τρισδιάστατο.	47
6.8	Ομαδοποίηση βημάτων χρόνου σε πρότυπο-αστέρι.	48
6.9	Holewinski κ.α. [2] Ομαδοποίηση βημάτων χρόνου για δισδιάστατο Jacobi	48
6.10	Πορεία της επιτάχυνσης για διαφορετική αναλογία στο μήκος των διαστάσεων. Πρότυπο-αστέρι με ακτίνα 8	49
6.11	Επιτάχυνση για διαφορετικές ακτίνες. Πρότυπο-αστέρι	50
6.12	Επιτάχυνση με FFT για διαφορετικές ακτίνες. Πρότυπο-αστέρι	51
6.13	Επιτάχυνση με FFT για διαφορετικές ακτίνες. Πυκνό πρότυπο	51
6.14	Επιτάχυνση με FFT για διαφορετικές πυκνότητες προτύπων	52
6.15	Επιτάχυνση με FFT για διαφορετικές ακτίνες. Δισδιάστατο πρότυπο-αστέρι	52
6.16	Επιτάχυνση με FFT για διαφορετικές ακτίνες. Δισδιάστατο πυκνό πρότυπο.	53
6.17	Επιτάχυνση με FFT για διαφορετικές πυκνότητες προτύπων	53

Τμήματα Κώδικα

3.1	C παράδειγμα με δήλωση τύπων	16
3.2	Julia παράδειγμα χωρίς δήλωση τύπων	16
3.3	C παράδειγμα προσπέλασης πίνακα	16
3.4	Julia παράδειγμα προσπέλασης πίνακα	17
3.5	Julia παράδειγμα με μακροεντολή @view. Μόνο ο αριθμός του νήματος (thread id) και η μεταβλητή της επανάληψης χρησιμοποιούνται για την προσπέλαση πίνακα.	17
3.6	C παράδειγμα με δήλωση τύπων.	23
3.7	Julia παράδειγμα με δήλωση τύπων.	23
5.1	Julia Παράδειγμα ορισμού προτύπου-αστέρι	36
5.2	Παράδειγμα ξεδιπλωμένου επαναληπτικού βρόγχου στον παρα-γόμενο κώδικα σε Julia.	38
6.1	Παράδειγμα παραγωγής κώδικα σε Julia.	54
6.2	Παράδειγμα εκτέλεσης συνάρτησης-πυρήνα σε Julia.	55
6.3	Παράδειγμα εκτέλεσης κώδικα σε κάρτα γραφικών χωρίς συνάρτηση πυρήνα σε Julia.	55
6.4	Δημιουργία επαυξημένου πίνακα σε Julia.	55
6.5	Δέσμευση ομογενοποιημένης μνήμης με CUDA σε Julia.	56
6.6	Αντιγραφή τμήμα μνήμης σε άλλο τμήμα μνήμης στις κάρτες γραφικών με Julia.	57
8.1	Julia παράδειγμα παραγώμενου κώδικα για τρισδιάστατο πρότυπο-αστέρι με ακτίνα 2.	62
8.2	Julia. Απλή εκδοχή συνάρτησης πυρήνα για εύρεση κοντινότερων γειτόνων.	64

Κεφάλαιο 1

Εισαγωγή

1.1 Εισαγωγή στις κάρτες γραφικών

Η αξιοποίηση των παράλληλων και διανεμημένων συστημάτων είναι απαραίτητη στην σύγχρονη εποχή, τόσο για εμπορικά προϊόντα όσο και στην έρευνα. Πολλά προβλήματα που ενδιαφέρουν μηχανικούς και επιστήμονες απαιτούν υπερβολικά πολύ χρόνο σε κλασικούς επεξεργαστές. Η εμπορική διάθεση πολυπύρηνων επεξεργαστών και καρτών γραφικών βοηθάει στην αύξηση του ρυθμού της έρευνας, στην επίλυση προβλημάτων που δεν λύνονται σε αποδεκτό χρόνο από μονοπύρηνους επεξεργαστές και στην παροχή υψηλής ταχύτητας προϊόντων λογισμικού από οργανισμούς.

Οι κάρτες γραφικών αποτελούν ένα μέρος του εξοπλισμού που χρησιμοποιούνται για υπολογισμούς υψηλής απόδοσης. Μεταλλάχθηκαν από υλικό πλήρως εξειδικευμένο στη δημιουργία γραφικών, σε γενικού σκοπού υπολογιστικές μονάδες. Επιστήμονες και μηχανικοί έχουν δημιουργήσει νέους αλγόριθμους οι οποίοι βασίζονται στην αρχιτεκτονική των καρτών γραφικών και έχουν αναλύσει πως γίνεται η πιο αποδοτική χρήση των πόρων τους. Οι κάρτες γραφικών χρησιμοποιούνται πλέον σε διάφορες εφαρμογές, όπως υπολογισμοί προτύπων, προβλήματα γραμμικής άλγεβρας, προσομοιώσεις δυναμικής ρευστών, νευρωνικά δίκτυα, μηχανική όραση και επεξεργασία σήματος.

Οι δύο πιο γνωστές πλατφόρμες για τον προγραμματισμό των καρτών γραφικών είναι η CUDA και η OpenCL. Η OpenCL είναι γενικότερου σκοπού πλατφόρμα και δεν εξειδικεύεται μόνο σε κάρτες γραφικών. Η CUDA έχει δημιουργηθεί από την NVIDIA για τις δικές της κάρτες γραφικών και έχει περισσότερες δυνατότητες από την OpenCL όσον αφορά την αξιοποίηση συγκεκριμένων πόρων και θεωρείται πιο ώριμη [3]. Οι βασικές γλώσσες που χρησιμοποιούνται για τον προγραμματισμό καρτών γραφικών είναι οι πλέον γνωστές C/C++, ενώ υπάρχει υποστήριξη και για Fortran

1.2 Εισαγωγή στην Julia

Η Julia είναι μια υψηλού επιπέδου γλώσσα που δημιουργήθηκε το 2012 και είναι εξειδικευμένη σε αριθμητικούς υπολογισμούς. Η Julia καταρρίπτει το στερεότυπο πως οι υψηλού επιπέδου γλώσσες είναι αργές και ότι η τελική υλοποίηση θα πρέπει να γραφτεί σε χαμηλότερου επιπέδου γλώσσα από ότι στο πρωτότυπο. Η ταχύτητά της σε εργασίες αριθμητικών υπολογισμών είναι ισάξιά της C/C++

Το 2018 η Julia άρχισε να υποστηρίζει προγραμματισμό για κάρτες γραφικών της NVIDIA. Ως γλώσσα υψηλού επιπέδου, επιτρέπει νέες και δυναμικές τεχνικές στον προγραμματισμό καρτών γραφικών, αυξάνει την παραγωγικότητα των προγραμματιστών, ενώ διατηρεί την απόδοση στα ίδια επίπεδα με αυτά που προσφέρουν τα εργαλεία της NVIDIA. Καθώς η υποστήριξη είναι πρόσφατη και σε πρώιμο στάδιο, πέρα από κάποιες βασικές μετρήσεις [4] που συγκρίνουν την ταχύτητα της Julia με C σε κάρτες γραφικών, δεν υπάρχουν μελέτες για το πώς επιτυγχάνεται αυτή η ταχύτητα σε προγράμματα ή πόσο παραγωγική είναι σε έρευνα.

1.3 Κίνητρο και στόχος της διπλωματικής εργασίας

Παρόλο που οι C/C++ φέρνουν τον προγραμματιστή πιο κοντά στο υλικό και στην εκμετάλλευση των πόρων του, η χαμηλού επιπέδου φύση τους αποτελεί εμπόδιο. Ως γλώσσες χαμηλού επιπέδου, χρειάζονται πολλές γραμμές κώδικα για να εκτελεστούν απλές εργασίες, είναι δύσκολο να γίνει αποσφαλμάτωση και συντήρηση και είναι περίπλοκο να γίνει ενσωμάτωση σε ή με άλλο πρόγραμμα. Οι χαμηλού επιπέδου γλώσσες δε βοηθούν στην παραγωγικότητα των προγραμματιστών και αυξάνουν το κόστος και τον χρόνο δημιουργίας προγραμμάτων, καθώς απαιτούν περισσότερο κόπο και αυξάνουν το νοητικό φορτίο.

Ο στόχος της παρούσας διπλωματικής είναι να εδραιώσει τη θέση της Julia ως καλή ή και καλύτερη εναλλακτική για προγραμματισμό καρτών γραφικών σε CUDA. Για το σκοπό αυτό χρειάζεται να μελετηθεί η απόδοσή της, σε επίπεδο κώδικα στοχευμένου μόνο για κάρτες γραφικών, σε επίπεδο ολοκληρωμένης εφαρμογής και σε συνθήκες πραγματικής έρευνας. Επιπροσθέτως με τη μελέτη της ταχύτητας χρειάζεται να γίνει ανάλυση της ποιότητας κώδικα που μπορεί να γράψει κάποιος προγραμματιστής και να γίνει σύγκριση με την ανάλογη ποιότητα σε C.

1.4 Οργάνωση Κειμένου

Στη συνέχεια της διπλωματικής εργασίας, που ξεκινάει με το Κεφάλαιο 2, παρουσιάζονται οι βασικές έννοιες της CUDA και της Julia που είναι απαραίτητες για την ανάλυση και τα συμπεράσματα που ακολουθούν στα επόμενα κεφάλαια. Στο Κεφάλαιο 3 γίνονται δύο μελέτες σε αυτοτελή προβλήματα για την ανάλυση της Julia σε επίπεδο κώδικα μόνο για κάρτα γραφικών. Στο Κεφάλαιο 4 παρουσιάζονται οι υπολογισμοί προτύπων σε κάρτες γραφικών και προηγούμενες έρευνες που χρησιμοποιούνται ως βάση για το επόμενο κεφάλαιο. Στο Κεφάλαιο 5 εξηγείται η υλοποίηση μιας πλατφόρμας για αυτόματη παραγωγή κώδικα προτύπου για κάρτες γραφικών. Στο κεφάλαιο 6 παρουσιάζονται τα αποτελέσματα, τόσο για ταχύτητα όσο και για ποιότητα κώδικα ενώ στο Κεφάλαιο 7 γίνεται εξαγωγή συμπερασμάτων και συζήτηση για τα προβλήματα που αντιμετωπίστηκαν, όπως και για περαιτέρω έρευνα.

Κεφάλαιο 2

Βασικές Έννοιες

2.1 CUDA και κάρτες γραφικών NVIDIA

Η CUDA (Compute Unified Device Architecture) αποτελεί μία πλατφόρμα παράλληλης επεξεργασίας, που επιτρέπει τον προγραμματισμό καρτών γραφικών που υποστηρίζουν αυτό το μοντέλο χωρίς να χρειάζεται γνώση αλγορίθμων γραφικής. Σε αντίθεση με άλλα προγραμματιστικά περιβάλλοντα, όπως OpenGL, DirectX, [5] δεν απαιτεί από τον προγραμματιστή την εκμάθηση καινούριας διεπαφής ή βιβλιοθήκης, αφού έχει σχεδιαστεί να δουλεύει με υπάρχουσες γλώσσες προγραμματισμού (C/C++).

2.1.1 Μοντέλο Προγραμματισμού

Το μοντέλο επεξεργασίας που ακολουθείται είναι το **SIMD** (Single Instruction Multiple Data) [6]. Δηλαδή, όλα τα νήματα εκτελούν τις ίδιες εντολές πάνω σε διαφορετικά δεδομένα.

Η CUDA επεκτείνει τις γλώσσες προγραμματισμού που υποστηρίζει, δίνοντας τη δυνατότητα στον προγραμματιστή να γράψει συναρτήσεις στην ίδια τη γλώσσα, οι οποίες θα εκτελεστούν N φορές παράλληλα σε N νήματα της CUDA. Κάθε νήμα που εκτελεί την συνάρτηση-πυρήνα έχει μια ενσωματωμένη μεταβλητή που περιέχει την ταυτότητα του νήματος. Η μεταβλητή αυτή είναι προσβάσιμη μέσα από τον κώδικα της συνάρτησης-πυρήνα.

Η ταυτότητα των νημάτων μπορεί να είναι μονοδιάστατη, δισδιάστατη ή τρισδιάστατη ανάλογα με τη μορφή των δεδομένων. Επιπλέον, τα νήματα οργανώνονται σε μπλοκ και τα μπλοκ σε πλέγματα. Η ταυτότητα των μπλοκ και των πλεγμάτων βρίσκεται επίσης σε ενσωματωμένες μεταβλητές και ακολουθεί την ίδια δεικτιοδότηση σχετικά με τις διαστάσεις. Ο προγραμματιστής ορίζει τον αριθμό τους πριν την εκτέλεση της συνάρτησης-πυρήνα. Ο συνολικός αριθμός των νημάτων σε μια εκτέλεση συνάρτησης πυρήνα υπολογίζεται μέσω της σχέσης:

$$\# \text{ νημάτων ανά μπλοκ} \times \# \text{ μπλοκ ανά πλέγμα} \times \# \text{ πλεγμάτων}$$

Συνήθως ο συνολικός αριθμός των νημάτων εξαρτάται από το μέγεθος των δεδομένων και μπορεί να ξεπερνάει κατά πολύ τον αριθμό νημάτων που μπορεί να εκτελέσει πραγματικά παράλληλα η κάρτα γραφικών.

2.1.2 Ιεραρχία Μνήμης

Τα νήματα CUDA έχουν πρόσβαση σε πολλούς χώρους μνήμης. Κάθε νήμα έχει τη δική του ιδιωτική τοπική μνήμη, που περιλαμβάνει καταχωρητές και ιδιωτικό χώρο στην καθολική μνήμη. Κάθε μπλοκ έχει τη δική του διαμοιραζόμενη μνήμη, στην οποία έχουν πρόσβαση όλα τα νήματα που ανήκουν στο μπλοκ. Τέλος, όλα τα νήματα, ανεξάρτητα από το μπλοκ και το πλέγμα που ανήκουν, έχουν πρόσβαση στην καθολική μνήμη.

Η τοπική και η διαμοιραζόμενη μνήμη μένουν “ζωντανές” μόνο κατά την εκτέλεση των νημάτων ή των μπλοκ που ανήκουν. Η καθολική μνήμη, διατηρεί τα δεδομένα, ακόμα και σε εκτελέσεις διαφορετικών συναρτήσεων πυρήνων.

Κάθε τύπος μνήμης, έχοντας διαφορετικά πλεονεκτήματα και περιορισμούς, προορίζεται για διαφορετική χρήση. Ακόμα, υπάρχουν 3 επίπεδα κρυφής μνήμης, που όμως δεν προγραμματίζονται απευθείας.

2.1.3 Αρχιτεκτονική Υλικού

Η αρχιτεκτονική των καρτών γραφικών της NVIDIA βασίζεται σε ένα πλέγμα από ειδικούς πολυ-νηματικούς επεξεργαστές, που ονομάζονται πολυεπεξεργαστές συνεχόμενης ροής (Streaming Multiprocessors). Όταν ένα πρόγραμμα CUDA καλείται από τον επεξεργαστή του υπολογιστή, τα μπλοκ νημάτων αριθμούνται και διανέμονται στους πολυ-επεξεργαστές ανάλογα με τη διαθέσιμη χωρητικότητα. Τα νήματα ενός μπλοκ εκτελούνται ταυτόχρονα σε έναν πολυ-επεξεργαστή, ενώ διαφορετικά μπλοκ του πλέγματος εκτελούνται σε διαφορετικούς πολυεπεξεργαστές. Στην πραγματικότητα, ο αριθμός των νημάτων και των μπλοκ που μπορούν να εκτελεστούν παράλληλα είναι περιορισμένος. Όταν ένα μπλοκ ολοκληρώσει την εκτέλεσή του, ένα νέο ξεκινά την εκτέλεση στη θέση του.

Σε χαμηλότερο επίπεδο, ο πολυεπεξεργαστής δημιουργεί, διαχειρίζεται και εκτελεί μια ομάδα από 32 νήματα, που ονομάζονται σμήνος (warp). Όταν εκτελείται ένα μπλοκ, τα νήματά του διαχωρίζονται σε σμήνη και κάποια είναι ενεργά (δηλαδή εκτελούνται) ενώ άλλα ανενεργά, περιμένοντας να βρεθούν διαθέσιμοι πόροι. Σε ένα σμήνος που είναι ενεργό, τα νήματά του εκτελούν πάντα κοινές εντολές, με τη μέγιστη αποδοτικότητα όταν δεν υπάρχουν διαφοροποιήσεις σε βρόγχους επανάληψης ή συνθήκες ελέγχου.

2.1.4 Βελτίωση Απόδοσης

Οι βασικές τεχνικές βελτιστοποίησης για την αύξηση της απόδοσης περιγράφονται από 3 κανόνες.


- Μεγιστοποίηση του αριθμού νημάτων που εκτελούνται πραγματικά παράλληλα.
- Βελτιστοποίηση της χρήσης μνήμης για μέγιστη ρυθμαπόδοσή της.
- Βελτιστοποίηση σε επίπεδο εντολών για μέγιστη ρυθμαπόδοσή τους.

Ο πρώτος κανόνας στοχεύει στη μέγιστη εκμετάλλευση των πολυεπεξεργαστών. Κάθε πολυεπεξεργαστής μπορεί να εκτελέσει περιορισμένο αριθμό μπλοκ παράλληλα. Επομένως, αν κάθε μπλοκ έχει λίγα νήματα, δεν αξιοποιείται πλήρως η επεξεργαστική

ισχύς. Το ίδιο ισχύει και για μικρό αριθμό μπλοκ που διαμοιράζονται στους πολυεπεξεργαστές. Παρόμοια κατάσταση ανεκμετάλλευτης επεξεργαστικής ισχύος εμφανίζεται όταν ζητούνται υπερβολικά πολλοί πόροι (κυρίως σε επίπεδο μνήμης). Για παράδειγμα, αν ένα μπλοκ ζητήσει μεγάλο τμήμα της περιορισμένης διαμοιραζόμενης μνήμης που έχει ένας πολυεπεξεργαστής, δε γίνεται να εκτελεστεί παράλληλα ο μέγιστος δυνατός αριθμός μπλοκ.


Όπως αναφέρθηκε προηγουμένως, κάθε μνήμη προορίζεται για διαφορετική χρήση και έχει τους δικούς της περιορισμούς.

Η καθολική μνήμη είναι η πιο αργή από τις μνήμες και πολλές φορές αποτελεί περιοριστικό παράγοντα στην επιτάχυνση. Η πρόσβαση στην μνήμη αυτή από τα νήματα πρέπει να έχει συγκεκριμένη μορφή για να αξιοποιηθεί πλήρως η ταχύτητα μεταφοράς δεδομένων που προσφέρει η κάρτα. Ένα σμήνος νημάτων πρέπει να κάνει ομαδοποιημένη πρόσβαση στη μνήμη (Coalesced Access), δηλαδή να προσπελαύνει συνεχόμενα τμήματά της. Έτσι τα δεδομένα διαβάζονται ή γράφονται παράλληλα, σε αντίθεση με προσπέλαση μη συνεχόμενων δεδομένων όπου γίνεται σειριακά στα διαφορετικά νήματα.



Σχήμα 2.1: Ομαδοποιημένη πρόσβαση στην καθολική μνήμη

Η διαμοιραζόμενη μνήμη παίζει το ρόλο κρυφής μνήμης, ελεγχόμενη όμως πλήρως από τον προγραμματιστή. Σε αυτήν αποθηκεύονται τα δεδομένα της καθολικής μνήμης, τα οποία μπορεί να χρησιμοποιηθούν σε περισσότερα από ένα νήματα. Ομοίως, σε αυτήν αποθηκεύονται τα αποτελέσματα, ώστε να εγγραφούν με ομαδοποιημένη προσπέλαση πίσω στην καθολική μνήμη. Για να επιτευχθεί η μέγιστη ταχύτητα χρειάζεται να μην υπάρχουν διαμάχες τραπεζών μνήμης (bank conflicts), δηλαδή να μη ζητούν πρόσβαση περισσότερα από ένα νήματα στην ίδια τράπεζα μνήμης. Ο τρόπος που χωρίζεται η μεριζόμενη μνήμη σε τράπεζες φαίνεται στο παρακάτω σχήμα.



Σχήμα 2.2: Οπτικοποίηση τραπεζών μνήμης στη μεριζόμενη μνήμη

Τέλος, οι καταχωρητές χρησιμοποιούνται για αποθήκευση δεδομένων τοπικά σε κάθε νήμα και για την εκτέλεση εντολών. Κάθε νήμα έχει τον δικό του χώρο καταχωρητών. Ο προγραμματιστής δε μπορεί να ορίσει ακριβώς τον αριθμό καταχωρητών που χρησιμοποιεί κάθε νήμα, αλλά μπορεί να μειώσει τη χρήση τους αποθηκεύοντας δεδομένα στην μεριζόμενη μνήμη.

2.1.5 Επιπλέον χαρακτηριστικά

Συγχρονισμός Το σμήνος νημάτων είναι η μόνη οντότητα που έχει έμφυτη τη συγχρονισμένη εκτέλεση εντολών. Επειδή γενικά τα νήματα εκτελούνται ταυτόχρονα αλλά όχι πάντα παράλληλα απαιτούνται ειδικές εντολές για τον συγχρονισμό τους, όταν υπάρχει πρόσβαση σε κοινούς πόρους, όπως η διαμοιραζόμενη μνήμη. Μόνο τα νήματα του ίδιου μπλοκ μπορούν να συγχρονιστούν χρησιμοποιώντας την εντολή `__syncthreads()`. Η εντολή αυτή χρησιμοποιείται κυρίως για να είμαστε σίγουροι ότι έχουν διαβαστεί όλα τα κοινά δεδομένα στη διαμοιραζόμενη μνήμη, πριν προσπαθήσει κάποιο νήμα να τα χρησιμοποιήσει.

Ο επόμενος δυνατός συγχρονισμός, είναι σε επίπεδο μπλοκ και επιτυγχάνεται με τη χρήση διαφορετικών κλήσεων συναρτήσεων-πυρήνων και την εντολή `__cudaDeviceSynchronize()` από τον επεξεργαστή του υπολογιστή.

Ομογενοποιημένη Διευθυνσιοδότηση Μνήμης Ένα πολύ σημαντικό χαρακτηριστικό, που μπορεί να εφαρμοστεί σε 64bit υπολογιστές, είναι η χρήση ενός ιδεατού χώρου διευθύνσεων μνήμης, τόσο για τις κάρτες γραφικών, όσο και για τον υπολογιστή. Ο προγραμματιστής ορίζει μόνο το μέγεθος και τον τύπο της μνήμης που θέλει, και η πλατφόρμα CUDA, ανάλογα με τη χρήση της μνήμης, καταλαβαίνει αν βρίσκεται στην κάρτα, στον επεξεργαστή ή και στα δύο και κάνει αυτόματα τις μεταφορές δεδομένων. Ακόμα πιο σημαντικό είναι ότι διευκολύνει τη διαχείριση μνήμης σε σύστημα με πολλές κάρτες γραφικών, αφού με την ίδια εντολή μεταφέρει δεδομένα από επεξεργαστή σε κάρτα, το αντίστροφο, και από κάρτα σε άλλη κάρτα.

2.2 Julia

Η Julia είναι μια υψηλού επιπέδου, υψηλής απόδοσης και δυναμική γλώσσα προγραμματισμού που στοχεύει στη λύση του “προβλήματος των δύο γλωσσών” που διέπει την έρευνα και τους τεχνικούς υπολογισμούς. Οι προγραμματιστές προτιμούν υψηλού επιπέδου γλώσσες για ανάλυση δεδομένων και ανάπτυξη αλγορίθμων καθώς είναι βολικές και αυξάνουν την παραγωγικότητα. Αντίθετα, για αποδοτικότητα σε υπολογιστικά έντονες διεργασίες, προτιμούν χαμηλού επιπέδου γλώσσες, όπως C/C++ και Fortran.

2.2.1 Μεταπρογραμματισμός και Ενδοσκόπηση

Ο μετα-προγραμματισμός είναι το σημαντικότερο κληροδότημα της LISP [7] στην Julia. Η Julia αναπαριστά τον κώδικά της ως δομή δεδομένων της ίδιας της γλώσσας, η οποία μπορεί να δημιουργηθεί και να τροποποιηθεί [8]. Έτσι, είναι δυνατόν να γίνει περίπλοκη παράγωγή κώδικα χωρίς επιπλέον βήματα μεταγλώττισης. Ακόμα, οι μακρο-εντολές λειτουργούν σε επίπεδο συντακτικού δέντρου, όπως και στην LISP, κάνοντας πιο εύκολη την ενσωμάτωση βελτιστοποιήσεων και αυξάνοντας την εκφραστικότητα. Αντίθετα, οι μακρο-εντολές στην C έχουν περιορισμένες δυνατότητες καθώς λειτουργούν σε επίπεδο αλφαριθμητικών, πριν γίνει συντακτική ανάλυση του κώδικα. Από τα παραπάνω χαρακτηριστικά, εξάγεται ότι η Julia υποστηρίζει και την ενδοσκόπηση κώδικα, που είναι πολύ χρήσιμη στρατηγική για τον προγραμματισμό και επιτρέπει την μετατροπή του εκτελέσιμου κώδικα κατά την εκτέλεση του προγράμματος.

2.2.2 LLVM και Δυναμική Μεταγλώττιση

Ένα από τα χαρακτηριστικά “δυναμισμού” που ενσωμάτωσαν οι δημιουργοί της Julia σε αυτή, είναι η δυνατότητα ο χρήστης να τρέξει κώδικα στο στάδιο το φορτώματος και στο στάδιο της υλοποίησης, απαλλάσσοντας τον από το χειροκίνητο “χτίσιμο” του κώδικα που αποσπά την προσοχή. Για να πετύχει αυτόν τον στόχο η Julia χρησιμοποιεί το μοντέλο της δυναμικής μεταγλώττισης και την πλατφόρμα LLVM.

Στο δυναμικό μοντέλο μεταγλώττισης υπάρχει μια συνεχής διαδικασία μεταγλώττισης του προγράμματος καθώς εκτελείται. Με κάθε εκτέλεση γίνεται ανίχνευση σημείων του κώδικα που μπορούν να βελτιστοποιηθούν και γίνεται επαναμεταγλώττιση.

Το LLVM [9] είναι μια πλατφόρμα μεταγλώττισης, που μπορεί να σε ενσωματωθεί σε οποιαδήποτε γλώσσα και δίνει πληροφορίες για τη μεταγλώττιση του προγράμματος καθόλη τη διάρκεια ζωής του (εκτέλεση, αναμονή, μεταγλώττιση).

Με αυτόν τον τρόπο, ο προγραμματιστής ασχολείται μόνο με τη σύνταξη κώδικα, μπορεί πολύ εύκολα να υλοποιήσει εφαρμογή που παράγει αυτόματα κώδικα και να εφαρμοστούν βελτιστοποιήσεις από την ίδια τη γλώσσα σε μη-καλά ορισμένους τύπους δεδομένων.

2.2.3 CUDA.jl

Η βιβλιοθήκη CUDA.jl [10] παρέχει δύο πολύ βασικές λειτουργίες για τον προγραμματισμό καρτών γραφικών. Αρχικά, όλες οι εντολές της CUDA σε C, που χρησιμοποιούνται για τον έλεγχο του υλικού των καρτών γραφικών, έχουν καλυφθεί από κώδικα Julia για

να είναι εύκολα προσβάσιμες από τον προγραμματιστή. Η δεύτερη λειτουργία είναι η μετατροπή κώδικα Julia σε κώδικα μηχανής κάρτας γραφικών. Αυτό επιτυγχάνεται ενσωματώνοντας τον μεταγλωττιστή της NVIDIA (NVTX) και χρησιμοποιώντας την πλατφόρμα LLVM, ρυθμισμένη διαφορετικά. Έτσι ο προγραμματιστής μπορεί να δημιουργήσει δυναμικές συναρτήσεις, οι οποίες για παράδειγμα μπορεί να τροποποιούν τον κώδικά τους και να τον εκτελούν απρόσκοπτα σε κάρτες γραφικών.

Η πλατφόρμα CUDA ενισχύεται με τη βιβλιοθήκη CuArrays [11], που είναι ενσωματωμένη στην βιβλιοθήκη CUDA.jl. Έχει δημιουργηθεί ένας νέος τύπος πίνακα, που καλύπτει πολλές από τις λειτουργίες της CUDA για διαχείριση μνήμης των καρτών γραφικών. Με τον νέο τύπο πίνακα, φαίνεται σαν να υπάρχει έμφυτη υποστήριξη από τη γλώσσα για διαχείριση μνήμης σε κάρτες γραφικών, καθώς ο τρόπος χρήσης τους μοιάζει με αυτόν των κανονικών πινάκων.

Κεφάλαιο 3

Μελέτες Περιπτώσεων

3.1 Εισαγωγή

Το πρώτο βήμα για να εδραιωθεί η Julia ως καλή ή και καλύτερη επιλογή για προγραμματισμό σε CUDA, είναι να συγκριθεί με τη C ως προς την ταχύτητα και την ποιότητα κώδικα. Παρόλο που ήδη υπάρχουν μετρήσεις που πραγματοποιούν αυτήν τη σύγκριση [4], το να γίνουν υλοποιήσεις από το μηδέν βοηθάει στην απόκτηση βαθύτερης γνώσης, εντοπισμό λεπτομερειών και πιο εύκολη αλλαγή του κώδικα για εκτενέστερη έρευνα.

3.2 Μελέτη 1 - Κοντινότερος Γείτονας σε πλέγμα

3.2.1 Περιγραφή Προβλήματος

Η εύρεση του κοντινότερου γείτονα σε πλέγμα (Grid KNN) είναι μια παραλλαγή του κανονικού αλγόριθμου εύρεσης κοντινότερων γειτόνων για τρισδιάστατα σημεία. Τα δεδομένα, τόσο εισόδου όσο και ερωτημάτων (queries) ταξινομούνται σε κύβους ίσου μεγέθους δημιουργώντας ένα πλέγμα. Η αναζήτηση του κοντινότερου γείτονα για ένα ερώτημα γίνεται πρώτα στον κύβο που ανήκει και έπειτα στους γειτονικούς κύβους.

3.2.2 Περιγραφή Υλοποίησης

Υλοποιήθηκε μόνο η περίπτωση που αναζητάμε τον έναν κοντινότερο γείτονα. Υπάρχουν δύο προσεγγίσεις: είτε να γίνει η αναζήτηση σε όλους τους γειτονικούς κύβους, χωρίς κάποιον έλεγχο (απλή εκδοχή), είτε να ελέγχεται αν κάποιος γείτονας είναι πιο κοντά από τις πλευρές των κύβων για να αποφευχθούν οι περιττές αναζητήσεις (εκδοχή με έλεγχο).

Για τις γλώσσες, οι υλοποιήσεις είναι πανομοιότυπες όσον αφορά την αλγοριθμική προσέγγιση, με τη διαφορά να βρίσκεται στο συντακτικό. Η Julia, στην απλή εκδοχή της, έχει τρεις διαφορετικές συντακτικές προσεγγίσεις

- "jl_simple" Ίδια με την υλοποίηση σε C. Οι τύποι των μεταβλητών δηλώνονται και η μόνη διαφορά είναι ότι χρησιμοποιείται τρισδιάστατη διευθυνσιοδότηση στους πίνακες.

- "jl_view" Η διαφορά με τα παραπάνω είναι ότι χρησιμοποιείται η μακροεντολή @view για να μη χρησιμοποιείται μετατόπιση διεύθυνσης σε όλο τον κώδικα.
- "jl_no_types" Ίδια με την παραπάνω απλά χωρίς να δηλώνονται οι τύποι των μεταβλητών.

Για την εκδοχή με έλεγχο ακολουθείται ο ίδιος τρόπος ονομασίας.

3.2.3 Ποιότητα Κώδικα

Δήλωση τύπων μεταβλητών Η Julia δεν απαιτεί να δηλώνουμε τον τύπο των μεταβλητών. Αυτό έχει ως αποτέλεσμα λιγότερο "γεμάτο" κώδικα.

Τμήμα Κώδικα 3.1: C παράδειγμα με δήλωση τύπων

```
int tid = threadIdx.x + threadIdx.y*blockDim.x;
int stride = blockDim.x*blockDim.y;
int start_points = intgr_points_per_block[p_bid];
int start_queries = intgr_queries_per_block[q_bid];
```

Τμήμα Κώδικα 3.2: Julia παράδειγμα χωρίς δήλωση τύπων

```
tid = threadIdx().x + (threadIdx().y-1)*blockDim().x
stride = (blockDim().x)*(blockDim().y)
startPoints = IntPointsperblock[p_bid]
startQueries = IntQueriesperblock[q_bid]
```

Θα περιμέναμε ότι είναι πολύ σημαντικό για προγραμματισμό σε κάρτες γραφικών να δηλώνονται οι τύποι. 64-bit αριθμητικές εντολές μπορεί να είναι έως και 8 φορές πιο αργές από τις αντίστοιχες 32-bit.

Προσπέλαση στοιχείων πίνακα Η Julia μπορεί να χρησιμοποιήσει πολυδιάστατη διευθυνσιοδότηση σε πίνακες της κάρτας γραφικών, τόσο στους καθολικούς (global) όσο και στους στατικούς και δυναμικούς μεριζόμενους (shared). Αντίθετα η C χρησιμοποιεί μονοδιάστατη γραμμική διευθυνσιοδότηση σε όλους τους πίνακες, εκτός από τους στατικούς μεριζόμενους πίνακες, όπου μπορεί να χρησιμοποιήσει και πολυδιάστατη.

Χρησιμοποιώντας πολυδιάστατη διευθυνσιοδότηση, ο κώδικας είναι πιο ευανάγνωστος και λιγότερο ευπαθής σε λογικά λάθη.

Τμήμα Κώδικα 3.3: C παράδειγμα προσπέλασης πίνακα

```
int q_index = q + tid + start_queries;
if(tid + q < total_queries){
    for(int d = 0; d < dimensions; d++){
        sh_queries[tid + d*stride]
            = queries[q_index + d*num_of_queries];
    }
    distance = distsances[q_index];
    neighbour = neighbours[q_index];
}
```

Τμήμα Κώδικα 3.4: Julia παράδειγμα προσπέλασης πίνακα

```
qIndex = startQueries + q + tid
if tid + q <= totalQueries
    for d = 1:dimensions
        @inbounds SharedQueries[d,tid] = Queries[qIndex, d]
    end
    @inbounds dist = Distances[qIndex]
    @inbounds nb = Neighbours[qIndex]
end
```

Δείκτης σε γραμμή ή στήλη Η πολυδιάστατη διευθυνσιοδότηση στην Julia συμπληρώνεται από την μακροεντολή `@view`, που επιτρέπει τον ορισμό ενός τμήματος πίνακα. Το ανάλογο στην C είναι η χρήση δείκτη (pointer) για τον ορισμό της έναρξης μιας γραμμής ή μιας στήλης ενός πίνακα. Οι δείκτες περιορίζονται στον ορισμό μονοδιάστατου τμήματος ενός πίνακα σε αντίθεση με τη μακροεντολή που μπορεί να ορίσει οποιονδήποτε υποπίνακα.

Τμήμα Κώδικα 3.5: Julia παράδειγμα με μακροεντολή `@view`. Μόνο ο αριθμός του νήματος (thread id) και η μεταβλητή της επανάληψης χρησιμοποιούνται για την προσπέλαση πίνακα.

```
# Defining the views
@inbounds Queries = @view devQueries[
    (startQueries+1):(startQueries+totalQueries), :]
@inbounds query = @view SharedQueries[:, tid]
@inbounds Distances = @view devDistances[
    (startQueries+1):(startQueries+totalQueries)]
@inbounds Neighbours = @view devNeighbours[
    (startQueries+1):(startQueries+totalQueries)]


...
# Reading Queries from Global Memory
if tid + q <= totalQueries
    for d = 1:dimensions
        @inbounds query[d] = Queries[tid+q, d]
    end
    @inbounds dist = Distances[tid+q]
    @inbounds nb = Neighbours[tid+q]
end
```

Συνηθισμένη πρακτική για κώδικα σε κάρτες γραφικών είναι ο διαχωρισμός των δεδομένων στα μπλοκ της κάρτας. Επομένως, αντί να χρησιμοποιούμε γραμμική διευθυνσιοδότηση και απόκλιση σε κάθε προσπέλαση πίνακα, μπορούμε να ορίσουμε τον υποπίνακα του κάθε μπλοκ με την μακροεντολή `@view`. Έτσι, γίνεται πιο κατανοητή η λογική του προγράμματος και δε χρειάζεται να σκεφτόμαστε κάθε φορά την περίπλοκη γραμμική διευθυνσιοδότηση.


3.2.4 Επίδοση και Μετρικές

Ο χρόνος εκτέλεσης κάθε υλοποίησης μετρήθηκε στις κάρτες γραφικών NVIDIA Tesla P100 και T4 για 2^{18} τρισδιάστατα σημεία με 2^3 και 2^4 μέγεθος πλέγματος, και για 2^{20} τρισδιάστατα σημεία με 2^4 και 2^5 μέγεθος πλέγματος

Η επιτάχυνση στα παρακάτω γραφήματα ορίζεται ως $\frac{\text{χρόνος της C}}{\text{χρόνος της Julia}}$ για δεδομένο μέγεθος προβλήματος.



Σχήμα 3.1: Σύγκριση Julia με C για simple GridKnn




Σχήμα 3.2: Σύγκριση Julia με C για simple GridKnn


Σε πρώτη ματιά, το πρόγραμμα σε C είναι πάντα πιο αργό από τουλάχιστον ένα πρόγραμμα σε Julia. Τα περισσότερα από τα προγράμματα σε Julia είναι περίπου δύο φορές

πιο γρήγορα, ενώ φτάνει έως και 3 φορές πιο γρήγορα.

Ομοίως στην εκδοχή με έλεγχο, η Julia είναι πιο γρήγορη, αλλά το χάσμα είναι μικρότερο.



Σχήμα 3.3: Σύγκριση Julia με C για GridKnn with Skip




Σχήμα 3.4: Σύγκριση Julia με C για GridKnn with Skip

Είναι ενδιαφέρον πως μία δυναμική, υψηλού επιπέδου γλώσσα μπορεί να είναι σημαντικά πιο γρήγορη από μια στατική, χαμηλού επιπέδου, σε ένα αντικείμενο που σχετίζεται άμεσα με το hardware. Ακόμα πιο ενδιαφέρον είναι πως δυο φαινομενικά ίδιοι

κώδικες παράγουν διαφορετική PTX γλώσσα μηχανής όπως φαίνεται από την επίδοση αλλά και από τις μετρικές παρακάτω.


Οι 3 βασικές μετρικές που γενικά χρησιμοποιούνται ως γνώμονας για βελτίωση των προγραμμάτων, έχουν τις ίδιες τιμές ανεξάρτητα από τη γλώσσα που χρησιμοποιήθηκε. Οι μετρικές αυτές είναι η απόδοση ανάγνωσης και εγγραφής καθολικής μνήμης, και η απόδοση πρόσβασης στην μεριζόμενη μνήμη. Οι μετρικές αυτές σχετίζονται με τον τρόπο που γίνεται η προσπέλαση σε πίνακες. Για την καθολική μνήμη, η ανάγνωση και αποθήκευση δεδομένων πρέπει να γίνεται ομαδικά (coalesced) από τα νήματα, ενώ στη μεριζόμενη μνήμη πρέπει να αποφεύγονται τα bank conflicts. Ήταν αναμενόμενο αυτές οι μετρικές να είναι ίδιες στις δύο γλώσσες.

Η χρήση διαφορετικού αριθμού καταχωρητών είναι η πρώτη ένδειξη ότι ο παραγόμενος κώδικας μηχανής είναι διαφορετικός.



Σχήμα 3.5: Χρήση καταχωρητών για GridKNN.

Ο οδηγός προγραμματισμού CUDA σε C [12] αναφέρει ότι όσο λιγότερους καταχωρητές χρησιμοποιεί μια συνάρτηση-πυρήνα, τόσο περισσότερα νήματα και ομάδες νημάτων μπορούν να τρέχουν ταυτόχρονα σε μια κάρτα γραφικών, βελτιώνοντας την απόδοση. Το πρώτο κομμάτι του ισχυρισμού ισχύει στην περίπτωσή μας, το δεύτερο όμως για την βελτίωση απόδοσης όχι.




Σχήμα 3.6: Αξιοποίηση πόρων κάρτας γραφικών.


Μια ακόμα σημαντική διαφορά σε μετρικές, είναι η διαφορά στον ρυθμό εγγραφής στην L2 κρυφή μνήμη. Η L2 κρυφή μνήμη χρησιμοποιείται ως μεσάζοντας σε διάβασμα και γράψιμο στην καθολική μνήμη. Ενώ η υλοποίηση σε C γράφει με ρυθμό εκατοντάδων MBps, η υλοποίηση σε Julia φτάνει την τάξη μεγέθους των GBps.

Παρόλο που το χάσμα στις μετρικές είναι αξιοσημείωτο, δεν παρέχει πολλή πληροφορία για τον τρόπο με τον οποίο διαφέρουν οι παραγόμενοι κώδικες μηχανής.

Τέλος, αξιοσημείωτη είναι και η επιρροή της μακροεντολής @view στην απόδοση των προγραμμάτων σε Julia.



Σχήμα 3.7: Julia - Επιτάχυνση με τη χρήση @view.



Σχήμα 3.8: Julia - Επιτάχυνση με τη χρήση @view.

Και στις δύο περιπτώσεις η χρήση του @view βελτιώνει αισθητά την απόδοση.

3.3 Μελέτη 2 - Αριθμός Τριγώνων σε Γράφο

Ο αριθμός των τριγώνων σε έναν συμμετρικό, μη κατευθυνόμενο γράφο, υπολογίζεται χρησιμοποιώντας τον πίνακα γειτνίασης A και τον τύπο $n = \frac{1}{6} \sum_{ij} (A \cdot A) \odot A$. Αξιοποιώντας τις ιδιότητες συμμετρίας για τον πίνακα A , ο τύπος μετατρέπεται σε $n = \sum_{ij} (U^T \cdot U) \odot U$, όπου U είναι το άνω τριγωνικό τμήμα του πίνακα γειτνίασης. Ο τελικός τύπος απλουστεύει το πρόβλημα σε σύγκριση των γραμμών και στήλων του U , που ορίζονται

από τα μη μηδενικά στοιχεία του ίδιου του U .

3.3.1 Περιγραφή Υλοποίησης

Υπάρχουν τρεις διαφορετικές εκδοχές, η κάθε μία με τα δικά της μειονεκτήματα:

- "row_per_th" Κάθε νήμα αναλαμβάνει μία γραμμή και ελέγχει κάθε στοιχείο της με όλες τις στήλες. (Μειονεκτήματα: Μεγάλη χρήση μεριζόμενης μνήμης, απόκλιση νημάτων, χαμηλή αξιοποίηση πόρων)
- "elem_per_th" Όλες οι γραμμές αποθηκεύονται στην μεριζόμενη μνήμη. Κάθε νήμα συγκρίνει ένα στοιχείο κάθε φορά με όλες τις γραμμές. (Μειονέκτημα: περισσότεροι υπολογισμοί, μεγάλη χρήση μεριζόμενης μνήμης)
- "elem_per_th_limit" Παρόμοιο με παραπάνω, αλλά αποθηκεύεται τμήμα των γραμμών κάθε φορά, για να είναι εφικτός ο υπολογισμός τριγώνων σε αραιούς γράφους με αρκετά μη μηδενικά στοιχεία σε κάποιες γραμμές. (Μειονέκτημα: περισσότεροι υπολογισμοί)

Κάθε εκδοχή γράφτηκε σε Julia δύο φορές, με και χωρίς δήλωση τύπων.

3.3.2 Ποιότητα Κώδικα

Δήλωση Τύπων Σε αυτό το πρόβλημα, η μη δήλωση τύπων στην Julia οδηγεί σε χαμηλή απόδοση. Όπως φαίνεται από τα επόμενα τμήματα κώδικα, οι δύο γλώσσες κινούνται στο ίδιο επίπεδο απλότητας.

Τμήμα Κώδικα 3.6: C παράδειγμα με δήλωση τύπων.

```
// ----- Read all the columns -----
for(int i = 0; i < len; i++){
    int col = sh_row[i];
    start_row = csr_rows[col];
    end_row = col==(rows-1)? nnz : csr_rows[col+1];
    int templen = end_row - start_row;
    if(tid == 0)
        sh_len[i] = templen;
    if(tid < templen){
        sh_cols[i*stride + tid] = col_indx[start_row + tid];
    }
}
```

Τμήμα Κώδικα 3.7: Julia παράδειγμα με δήλωση τύπων.

```
# #Read all the other rows
for i::Int32 = 1:len
    if threadIdx().x == 1
        @inbounds col::Int32 = sh_row[i]
        @inbounds row_start = csr_rows[col]
        @inbounds row_end =
            (col == rows) ? nnz+Int32(1) : csr_rows[col + 1]
    end
```

```

row_start = shfl_sync(0xffffffff, row_start, 1)
row_end = shfl_sync(0xffffffff, row_end, 1)
templen::Int32 = row_end-row_start
(tid==1) && (sh_len[i] = templen)
if tid <= templen
    @inbounds sh_cols[i,tid] = col_indx[row_start+tid-1]
end
end
end

```


Προσπέλαση Πίνακα

Ο αραιός πίνακας γειτνίασης αποθηκεύεται σε μορφή CSR (Compressed Sparse Rows). Έτσι κάθε πίνακας είναι μονοδιάστατος και η Julia δε μπορεί να αξιοποιήσει την πολύ χρήσιμη πολυδιάστατη διευθυνσιοδότηση.

Επιπλέον, η C μπορεί μέσω των δεικτών να ορίσει ένα τμήμα του πίνακα. Αυτή τη φορά η Julia δεν επωφελείται, σε σχέση με τη C, απο τη χρήση της μακροεντολής @view.

3.3.3 Απόδοση και Μετρικές

Όλες οι υλοποιήσεις εκτελέστηκαν στην Tesla P100 κάρτα γραφικών. Ακόμα, οι υλοποιήσεις με δήλωση τύπων εκτελέστηκαν και στην Tesla T4. Τρία σαι δεδομένων χρησιμοποιήθηκαν, με διαφορετικό μέγεθος, μέσο και μέγιστο αριθμό μη μηδενικών στοιχείων ανά γραμμή.



Σχήμα 3.9: C - Επιτάχυνση με δήλωση τύπων.




Σχήμα 3.10: C - Επιτάχυνση με δήλωση τύπων.

Η C, σε κάθε εκδοχή της, είναι πιο γρήγορη από τη Julia. Η επιτάχυνση κυμαίνεται κοντά στο 1.3x. Η χειρότερη απόδοση της Julia βρίσκεται στην 3η εκδοχή, όπου είναι 1.8x πιο αργή.


Για ακόμα μια φορά, οι τρεις βασικές μετρικές (απόδοση ανάγνωσης και εγγραφής καθολικής μνήμης, και η απόδοση πρόσβασης στην μεριζόμενη μνήμη) έχουν ίδιες τιμές για κάθε εκδοχή.

Αντίστοιχα με πριν, η Julia χρησιμοποιεί περισσότερους καταχωρητές.



Σχήμα 3.11: Χρήση καταχωρητών.

Όπως αναφέρθηκε και προηγουμένως, η μη δήλωση τύπων μειώνει την απόδοση.



Σχήμα 3.12: Julia - Επιτάχυνση με δήλωση τύπων.

Παρατηρούμε πως η δήλωση τύπων έχει ως αποτέλεσμα τουλάχιστον $\times 1.5$ επιτάχυνση. Αυτό το αποτέλεσμα έρχεται σε σύγκρουση με τις μετρήσεις από το πρόβλημα του κοντινότερου γείτονα σε πλέγμα, όπου έχουμε καλύτερες ταχύτητες όταν δε δηλώνονται τύποι.

Τέλος, ο ρυθμός εγγραφής στην L2 κρυφή μνήμη είναι 12 φορές μεγαλύτερος στην Julia, όπως και στο προηγούμενο πρόβλημα.

3.4 Σχόλια

Οι μελέτες δεν κατέληξαν σε μια συγκεκριμένη "συνταγή" για να γράφουμε τον πιο γρήγορο και αποδοτικό κώδικα σε Julia για κάρτες γραφικών. Στην πρώτη περίπτωση, η δήλωση τύπου αύξησε την ταχύτητα, ενώ στη δεύτερη συνέβη το αντίθετο. Επίσης στο πρόβλημα του κοντινότερου γείτονα σε πλέγμα, η Julia ήταν πιο γρήγορη, ενώ στο πρόβλημα μέτρησης τριγώνων ήταν σημαντικά πιο αργή.

Επίσης, αξιοσημείωτη είναι η συνεισφορά της μακροεντολής `@view` τόσο στην ποιότητα κώδικα, όσο και στην επιτάχυνση. Είναι περίεργο πώς ένα χαρακτηριστικό γλώσσας υψηλού επιπέδου βελτιώνει την απόδοση σε μια διαδικασία χαμηλού επιπέδου.

Μια πιθανή περιοχή για περισσότερη έρευνα είναι ο λόγος για τον οποίο ο μεταγλωττιστής NVTX της Julia παράγει διαφορετικό κώδικα μηχανής από τον μεταγλωττιστή `nvcc` για C. Μια τέτοια έρευνα θα μπορούσε να εξηγήσει γιατί η Julia χρησιμοποιεί περισσότερους καταχωρητές, πώς τους αξιοποιεί και πώς ο προγραμματιστής μπορεί να το εκμεταλλευτεί.

Όσον αφορά τον υπόλοιπο κώδικα, εκτός δηλαδή από την συνάρτηση-πυρήνα, η Julia φαίνεται να χρειάζεται λιγότερες γραμμές κώδικα για την επικοινωνία και μεταφορά

δεδομένων στην κάρτα γραφικών. Επιπλέον, είναι πολύ πιο εύκολη η προεπεξεργασία δεδομένων και η επαλήθευση του αποτελέσματος, λόγω του υψηλού επιπέδου της Julia, χωρίς να μειώνεται η συνολική απόδοση.

Κεφάλαιο 4

Υπολογισμοί Προτύπων

4.1 Ορισμός του προτύπου

Οι υπολογισμοί προτύπων είναι μια τάξη επαναληπτικών διαδικασιών και χρησιμοποιούνται σε πληθώρα εφαρμογών. Περιλαμβάνουν μια σειρά περασμάτων (βήματα-χρόνου) πάνω σε έναν πίνακα δεδομένων. Σε κάθε χρόνο, ανανεώνονται οι τιμές των σημείων σύμφωνα με μια συνάρτηση των γειτονικών τους σημείων. Το γεωμετρικό σχήμα αυτής της γειτονιάς αποτελεί το πρότυπο.

Οι υπολογισμοί προτύπων χρησιμοποιούνται στην προσομοίωση ενός συστήματος για πολλαπλά βήματα χρόνου ή για να διαπιστωθεί αν ένα σύστημα συγκλίνει σε μια κατάσταση σε βάθος χρόνου. Ακόμα, τα πρότυπα χρησιμοποιούνται σε προβλήματα που λύνονται από μεθόδους πεπερασμένων διαφορών, για την αριθμητική επίλυση μερικών διαφορικών εξισώσεων, στα κυτταρικά αυτόματα (cellular automata), στην επεξεργασία εικόνων και σε άλλα επιστημονικά πεδία.


Στην απλή τους μορφή, τα πρότυπα εφαρμόζονται σε μόνο ένα κανονικό πλέγμα, ενώ οι εκδοχές που εφαρμόζονται σε μη-δομημένα ή πολλαπλά πλέγματα είναι αρκετά πιο πολύπλοκες.

Ο χρόνος υπολογισμού και η χρήση μνήμης για τον υπολογισμό προτύπου αυξάνεται γραμμικά με τον όγκο δεδομένων. Επομένως, παράλληλες υλοποιήσεις για τον υπολογισμό προτύπου έχουν πολύ μεγάλη σημασία για τους ερευνητές [13].

Ένα χαρακτηριστικό παράδειγμα εφαρμογής προτύπου, είναι η τρισδιάστατη διακριτή Λαπλασιανή,

$$D^{t+1}[x, y, z] = \alpha D^t[x, y, z] + \beta (D^t[x-1, y, z] + D^t[x+1, y, z] + D^t[x, y-1, z] + D^t[x, y+1, z] + D^t[x, y, z-1] + D^t[x, y, z+1])$$

που είναι ανάλογη με τον συνεχή Λαπλασιανό τελεστή: $\nabla = \Delta^2 = (\frac{\partial^2}{\partial^2 x} + \frac{\partial^2}{\partial^2 y} + \frac{\partial^2}{\partial^2 z})$.



Σχήμα 4.1: Οπτικοποίηση προτύπου για ένα στοιχείο και βήμα χρόνου για την δισδιάστατη διακριτή Λαπλασιανή.

4.2 Πρότυπα σε κάρτες γραφικών

Οι υπολογισμοί προτύπων είναι από τη φύση τους παράλληλο πρόβλημα. Η τιμή κάθε στοιχείου στο επόμενο βήμα χρόνου μπορεί να υπολογιστεί ανεξάρτητα από τα υπόλοιπα στοιχεία. Αυτό μπορεί πολύ εύκολα να το εκμεταλλευτεί η κάρτα γραφικών για επιτάχυνση. Παρόλα αυτά, ο έμφυτος παραλληλισμός δεν οδηγεί στην αποδοτικότερη λύση. [13]. Οι υπολογισμοί προτύπων εφαρμόζονται σε δεδομένα που ξεπερνούν σε μέγεθος τις διαθέσιμες κρυφές μνήμες, ενώ η επαναχρησιμοποίηση δεδομένων περιορίζεται από το μικρό αριθμό σημείων που περιλαμβάνει το σχήμα του προτύπου. Έτσι, στα πολυ-πύρηνα συστήματα, η ταχύτητα υπολογισμού περιορίζεται από τη ρυθμαπόδοση της μνήμης. [2]. Η αναδιάταξη των υπολογισμών για την πλήρη αξιοποίηση της ιεραρχίας μνήμης μαζί με άλλες τεχνικές βελτιστοποίησης αποτελούν το αντικείμενο έρευνας εδώ και πολλά χρόνια.

4.3 Βελτιστοποίηση

4.3.1 Μοτίβο Προσπέλασης Μνήμης

[12] Η βελτιστοποίηση της χρήσης μνήμης είναι το πιο σημαντικό κομμάτι για την αύξηση της επιτάχυνσης και απαραίτητη για τους υπολογισμούς προτύπων που περιορίζονται από τη ρυθμαπόδοση της μνήμης. Η ανάγνωση και εγγραφή δεδομένων στις κάρτες γραφικών είναι από τις πιο αργές διαδικασίες και χρειάζονται συγκεκριμένα μοτίβα προσπέλασης για την πλήρη αξιοποίηση της ρυθμαπόδοσης.

Για τα δισδιάστατα πρότυπα ο τρόπος προσπέλασης μνήμης είναι προφανής. Κάθε ομάδα νημάτων διαβάσει ένα τετράγωνο από τα δεδομένα στην μεριζόμενη μνήμη. Έτσι, αξιοποιεί τις ομαδικές (coalesced) προσπελάσεις νημάτων και μπορεί να επαναχρησιμοποιήσει δεδομένα. Έπειτα κάθε νήμα μπορεί να διαβάσει τα δεδομένα που χρειάζεται από τη μεριζόμενη μνήμη χωρίς να υπάρχει διαμάχη στις τράπεζες μνήμης, αφού τα δεδομένα που διαβάζονται είναι συνεχόμενα σε μια γραμμή.

Για τα τρισδιάστατα πρότυπα, η διαδικασία είναι πιο περίπλοκη. Ακολουθώντας την ίδια λογική με τις δύο διαστάσεις, ένας κύβος από τα δεδομένα μεταφέρεται στη μεριζόμενη μνήμη. Οι ομαδικές προσπελάσεις αξιοποιούνται και οι διαμάχες στις τράπεζες μνήμης αποφεύγονται. Παρόλα αυτά, η προσέγγιση αυτή χρησιμοποιεί υπερβολικά πολλή μνήμη που οδηγεί σε μειωμένη εκμετάλλευση των πόρων της κάρτας γραφικών ή ακόμα και σε αδυναμία εκτέλεσης αν η μνήμη που απαιτείται ξεπερνάει τη διαθέσιμη. Ο Micikencious [14] παραθέτει μια υλοποίηση για κάρτες γραφικών στην οποία διαβάζει ένα τετράγωνο μνήμης στη μεριζόμενη μνήμη και χρησιμοποιεί τους καταχωρητές για την τρίτη διάσταση, εξοικονομώντας μεριζόμενη μνήμη. Ο κώδικας της υλοποίησης επικεντρώνεται μόνο σε τρισδιάστατες πεπερασμένες διαφορές και δεν μπορεί να εφαρμοστεί για άλλα σχήματα προτύπων. Ο Mo κ.α. [15] παρουσιάζουν μια τροποποιημένη υλοποίηση στην οποία χρησιμοποιούν τους καταχωρητές όχι για την ανάγνωση δεδομένων, αλλά για την αποθήκευση μερικών αποτελεσμάτων. Πέρα από την αποδοτικότερη χρήση μνήμης, η υλοποίηση αυτή μπορεί να εφαρμοστεί σε οποιοδήποτε σχήμα προτύπου.


4.3.2 Αλλαγή Μεγέθους Πίνακα

[12] Οι εντολές ελέγχου ροής έχουν σημαντική επιρροή στην ταχύτητα εκτέλεσης. Όταν υπάρχει διακλάδωση, δηλαδή κάθε νήμα δεν ακολουθεί το ίδιο "μονοπάτι", τα διαφορετικά μονοπάτια εκτελούνται σειριακά και όχι παράλληλα. Στους υπολογισμούς προτύπων, διακλάδωση εντολών ελέγχου εμφανίζεται όταν γίνεται έλεγχος αν κάποιο στοιχείο βρίσκεται εντός των ορίων του πίνακα. Για να αποφευχθεί αυτό το πρόβλημα, αυξάνουμε το μέγεθος του πίνακα, γεμίζοντας τις άκρες με μηδενικά, ώστε να είμαστε απολύτως σίγουροι ότι δε θα υπάρχει προσπάθεια πρόσβασης σε στοιχείο εκτός των ορίων. Επιπροσθέτως, μπορούμε να αυξήσουμε κι άλλο το μέγεθος του πίνακα, ώστε να είναι πολλαπλάσιο του 32 (μέγεθος σμήνους) και να μην γίνεται έλεγχος στα άκρα για αδρανή νήματα.


4.3.3 Ομαδοποίηση στον χρόνο

Η ομαδοποίηση στον χρόνο αποτελεί μια μέθοδο βελτιστοποίησης που στοχεύει στην επαναχρησιμοποίηση των δεδομένων που έχουν ήδη διαβαστεί σε κάποια γρήγορη μνήμη. Στην απλή της μορφή, η συνάρτηση για τον υπολογισμό προτύπου υπολογίζει μόνο ένα βήμα στον χρόνο και καλείται όσες φορές χρειάζεται. Αυτό σημαίνει ότι σε κάθε κλήση τα δεδομένα διαβάζονται και αποθηκεύονται στην καθολική μνήμη, το οποίο όπως έχει αναφερθεί, είναι αργό. Ομαδοποιώντας περισσότερα βήματα χρόνου σε μία κλήση μειώνονται οι προσπελάσεις στην καθολική μνήμη.


Η ομαδοποίηση στον χρόνο έχει εφαρμοστεί επιτυχώς για μονοδιάστατα και διδιάστατα πρότυπα, σε διάφορες αρχιτεκτονικές, μονοπύρηνια [16] και πολυπύρηνια [17] συστήματα και κάρτες γραφικών [2], φτάνοντας μέχρι και 5x επιτάχυνση. Συγκεκριμένα για τις κάρτες γραφικών, η μέθοδος αυτή υλοποιείται εφαρμόζοντας το πρότυπο περισσότερες από μία φορές στα δεδομένα που έχουν διαβαστεί στη μεριζόμενη μνήμη. Αυτό απαιτεί να διαβαστούν περισσότερα δεδομένα στη μνήμη και να γίνουν περιττές πράξεις για την ανανέωση των τιμών των επιπλέον στοιχείων.



Σχήμα 4.2: Ένα βήμα χρόνου για το κεντρικό στοιχείο. Δε χρειάζονται επιπλέον στοιχεία.



Σχήμα 4.3: Δύο βήματα χρόνου για το κεντρικό στοιχείο. Χρειάζονται επιπλέον στοιχεία, τα οποία όμως έχουν ήδη διαβαστεί στο κανονικό στεφάνι(halo).



Σχήμα 4.4: Δύο βήματα χρόνου για το κεντρικό στοιχείο. Χρειάζονται επιπλέον στοιχεία για το στεφάνι και απαιτούνται περιττές πράξεις για την ανανέωσή του.

Στο σχήμα 4.2 παρουσιάζεται η περίπτωση για ένα βήμα χρόνου στο κεντρικό στοιχείο. Τα δεδομένα που χρειάζονται βρίσκονται στο βασικό τετράγωνο. Στο σχήμα 4.3 για δύο βήματα χρόνου τα γαλάζια στοιχεία χρειάζεται να ανανεωθούν για να υπολογιστεί η τιμή του κεντρικού σημείου για δύο βήματα χρόνου. Για την ανανέωση των γαλάζιων στοιχείων χρειάζεται να διαβαστεί ένα στεφάνι γύρω από το τετράγωνο των δεδομένων. Στο σχήμα 4.4 για τρία βήματα χρόνου, πρέπει να ανανεωθούν οι τιμές του στεφανιού και έτσι πρέπει να αυξηθεί το μέγεθός του.

Είναι σημαντικό να αναφερθεί ότι τα στοιχεία του στεφανιού είναι μέρος του βασικού τετραγώνου μιας άλλης ομάδας νημάτων και για αυτό θεωρούνται περιττές πράξεις οι ανανεώσεις του στεφανιού.

Επίσης, για μια ομάδα νημάτων, όσο πιο πολλά βήματα χρόνου ομαδοποιούνται, τόσο πιο μικρό γίνεται το βασικό τετράγωνο για να μη υπάρχουν εντολές ελέγχου που εμποδίζουν την παραλληλοποίηση εντολών.

Είναι πολύ σημαντικό να ισορροπιστούν τα παραπάνω μειονεκτήματα με τη μείωση προσπέλασης καθολικής μνήμης για να βρεθεί ο κατάλληλος αριθμός βημάτων χρόνου που ομαδοποιείται. Τέτοια έρευνα σε κάρτες γραφικών και σε διαφορετικά σχήματα προτύπων έχουν πραγματοποιήσει ο Meng κ.α. [1]

Στις τρεις διαστάσεις, η χρήση μεριζόμενης μνήμης και οι περιττές πράξεις αυξάνονται πολύ γρηγορότερα με τον αριθμό βημάτων χρόνου. Ο Holewinski κ.α., όπως και ο Meng κ.α. δεν κατάφεραν καμία επιτάχυνση με ομαδοποίηση στον χρόνο για τρισδιάστατα πρότυπα. Ο Nguyen κ.α. πέτυχαν 1.8x επιτάχυνση, αλλά η μέθοδός τους δεν είναι κατάλληλη για αυτόματη παραγωγή υψηλής ταχύτητας κώδικα για κάρτες γραφικών.

4.3.4 Αυτόματη Ρύθμιση

Η αυτόματη ρύθμιση παραμέτρων για συναρτήσεις-πυρήνες κάρτας γραφικών έχει εφαρμοστεί με επιτυχία σε διάφορες περιπτώσεις, όπως σε αραιά και πυκνά προβλήματα γραμμικής άλγεβρας και επεξεργασίας σημάτων. Οι προγραμματιστές που γράφουν προγράμματα σε CUDA πρέπει να προσδιορίσουν τον αριθμό των νημάτων ανά ομάδα, το πλήθος των ομάδων, καθώς και παραμέτρους από μεθόδους βελτιστοποίησης που βρίσκονται στο εσωτερικό της συνάρτησης-πυρήνα. Οι προγραμματιστές μπορεί να μην έχουν τη διαίσθηση που απαιτείται για να ορίσουν αυτές τις παραμέτρους, οι οποίες έχουν περίπλοκες και απρόβλεπτες συσχετίσεις μεταξύ τους [18]. Επομένως η αυτόματη ρύθμιση των παραμέτρων είναι αναγκαία διαδικασία για να βρεθεί η καλύτερη επιλογή μέσα από τον εκτενή και περίπλοκο χώρο των ρυθμίσεων.

Για τους υπολογισμούς προτύπων έχουν προταθεί αρκετές πλατφόρμες [13] [18] [19] [20] οι οποίες υπολογίζουν τις παραμέτρους εκτέλεσης (αριθμό νημάτων και ομάδων) καθώς και αριθμό βημάτων χρόνου για τη ομαδοποίηση στον χρόνο, πόσο χρειάζεται να ξεδιπλωθούν οι βρόγχοι επανάληψης κ.α. Ενδεικτικά, τεχνικές που χρησιμοποιούν είναι παραμετροποίηση του χώρου των ρυθμίσεων, μηχανική μάθηση ή και ευριστικούς κανόνες. Μία αξιοσημείωτη υλοποίηση, που διαφέρει από τις προηγούμενες, δημιούργησε ο Lim κ.α. [18], όπου αναλύει στατικά τον παραγόμενο κώδικα μηχανής PTX, εκτιμάει διάφορες μετρικές και ορίζει τις παραμέτρους χωρίς το μεγάλο κόστος εκτέλεσης της συνάρτησης πυρήνα.

4.3.5 Αυτόματη Παραγωγή Κώδικα

Η αυτόματη παραγωγή παράλληλου κώδικα αποτελεί ένα πολύ σημαντικό πεδίο έρευνας και έχει ως στόχο να κρύψει από τους ερευνητές άλλων πεδίων τη δύσκολη διαδικασία επιτάχυνσης προγραμμάτων με τεχνικές παραλληλοποίησης. Πλατφόρμες όπως LibGeoDecomp [21], PATUS [22] και του Holewinski [2] παράγουν αποδοτικό παράλληλο κώδικα, για διάφορες αρχιτεκτονικές, συμπεριλαμβανομένου καρτών γραφικών, ενσωματώνοντας τεχνικές βελτιστοποίησης εσωτερικά στις συναρτήσεις-πυρήνες με μεγάλη επιτυχία. Ο χρήστης δίνει ως είσοδο την περιγραφή του προβλήματος/προτύπου σε μια εξειδικευμένη γλώσσα προγραμματισμού, η οποία μετά αναλύεται συντακτικά, παράγεται ο παράλληλος κώδικας και εκτελείται με τα δεδομένα που έχουν δοθεί. Μια σημαντική παρατήρηση είναι πως οι παραπάνω πλατφόρμες έχουν περίπλοκη δομή καθώς χρησιμοποιούν εξωτερικές βιβλιοθήκες/πλατφόρμες, γραμμένες σε διαφορετικές γλώσσες, για την ανάλυση και παραγωγή κώδικα.

Κεφάλαιο 5

Πλατφόρμα για παραγωγή κώδικα προτύπου και εκτέλεση σε πολλαπλές κάρτες γραφικών

5.1 Κίνητρο

Οι υπολογισμοί προτύπων χρησιμοποιούνται σε ένα μεγάλο εύρος επιστημονικών πεδίων. Η σύνταξη μιας συνάρτησης πυρήνα από την αρχή ή η τροποποίηση κάποιας υπάρχουσας υλοποίησης δεν είναι αποδοτικές λύσεις και μπορεί εύκολα να γίνουν λάθη.

Η απόκρυψη της διαδικασίας σύνταξης και επιτάχυνσης των προγραμμάτων είναι πολύ σημαντική για την αποδοτικότητα των ερευνητών, καθώς μειώνει την πιθανότητα ανθρώπινου λάθους, τον χρόνο ανάπτυξης και εκτέλεσης.

Όπως αναφέρθηκε στο προηγούμενο κεφάλαιο, οι υπάρχουσες πλατφόρμες για αυτόματη παραγωγή κώδικα έχουν περίπλοκη δομή με εξωτερικές βιβλιοθήκες και είναι γραμμένες με διαφορετικές γλώσσες. Επιπλέον, η διεπαφή με τον χρήστη σε κάποια είναι γραμμένη σε C++, μια χαμηλού επιπέδου γλώσσα που περιορίζει την εκφραστικότητα στον ορισμό του προβλήματος και χρειάζεται περισσότερες γραμμές τυπικού κώδικα.

5.2 Σκοπός και Περιγραφή της πλατφόρμας

Η βασική λειτουργία της πλατφόρμας είναι η αυτόματη παραγωγή κώδικα για υπολογισμό προτύπου σε κάρτες γραφικών. Επιπλέον, ενσωματώνει στη συνάρτηση-πυρήνα τεχνικές βελτιστοποίησης σύμφωνα με παραμέτρους που ορίζει ο χρήστης και μπορεί να εκτελέσει υπολογισμούς προτύπων σε μία ή περισσότερες κάρτες γραφικών ή ακόμα και μέσω FFT. Πέρα από την έρευνα, στην επιτάχυνση υπολογισμών προτύπου σε κάρτες γραφικών, η πλατφόρμα αυτή δημιουργήθηκε με σκοπό την ανάδειξη της Julia ως κατάλληλης γλώσσας για την υλοποίηση ενός ολοκληρωμένου προγράμματος, χωρίς την ανάγκη για εξωτερικές βιβλιοθήκες και με εξίσου καλή επιτάχυνση. Συγκεκριμένα, οι στόχοι για την Julia είναι να δείξουμε ότι μπορεί:

- να δημιουργήσει μια απλή και κατανοητή διεπαφή για τον χρήστη χωρίς να απαιτεί πολλές γραμμές κώδικα από αυτόν.
- να αναλύσει εύκολα συντακτικά κώδικα που έχει δώσει ως είσοδο ο χρήστης.
- να παράγει αυτόματα αποδοτικό κώδικα και να εφαρμόζει μεθόδους βελτιστοποίησης.
- να έχει υψηλή απόδοση στις εκτελέσεις σε μία κάρτα γραφικών.
- να εκμεταλλευτεί εύκολα περισσότερες από μια κάρτες γραφικών.

Όσον αφορά το κομμάτι της έρευνας για την επιτάχυνση των υπολογισμών προτύπων, παρουσιάζονται δύο καινούριες τεχνικές:


- ομαδοποίηση στον χρόνο για μη ολιστικές υλοποιήσεις για πρότυπο
- εκτέλεση πολλών βημάτων χρόνου με FFT

Πέρα από τις μετρήσεις και τα συμπεράσματα για την επιτάχυνση των υπολογισμών προτύπων είναι σημαντικό να μελετηθεί η συνεισφορά της Julia στην ερευνητική διαδικασία. Δηλαδή, αν δίνει ευελξία στον ερευνητή να υλοποιήσει ή να τροποποιήσει λειτουργίες του προγράμματός του και να μετατρέψει εύκολα τις ιδέες του σε πρωτότυπο.

5.3 Δομή της πλατφόρμας

Η πλατφόρμα αποτελείται από 4 δομικά στοιχεία. Ο *συντακτικός αναλυτής*, ο οποίος δέχεται ως είσοδο κώδικα Julia (expression) και τον τροποποιεί. Στη συνέχεια το δεύτερο δομικό στοιχείο τροποποιεί αυτόν τον κώδικα και τον μετατρέπει σε συμβολικά μαθηματικά. Σε αυτό το σημείο γίνεται και η μαθηματική έκφραση για την ομαδοποίηση στον χρόνο. Τρίτον, ο *παραγωγός κώδικα* μετατρέπει τα συμβολικά μαθηματικά σε αριθμητικές εντολές και δημιουργεί τη συνάρτηση-πυρήνα για την κάρτα γραφικών. Τέλος, το *σύστημα εκτέλεσης* είναι υπεύθυνο για την επικοινωνία με τις κάρτες γραφικών, την κατάλληλη επεξεργασία των δεδομένων και την εκτέλεση της συνάρτησης που έχει παραχθεί.

Όλα τα δομικά στοιχεία είναι γραμμένα σε Julia με τη βοήθεια βιβλιοθηκών γραμμένες στην ίδια γλώσσα. Η χρήση εξωτερικών προγραμμάτων/βιβλιοθηκών ή άλλης γλώσσας δεν ήταν αναγκαία.



Σχήμα 5.1: Γενική εικόνα της αρχιτεκτονικής.

Καθορισμός του προτύπου και συντακτική ανάλυση Ο χρήστης μπορεί να καθορίσει το πρότυπο με δύο τρόπους. Είτε να δώσει ως είσοδο ένα τρισδιάστατο πίνακα με συντελεστές, είτε τη μαθηματική έκφραση μέσω κώδικα. Η περίπτωση με τον τρισδιάστατο πίνακα είναι πολύ απλή και δε χρειάζεται συντακτική ανάλυση. Για τη δεύτερη περίπτωση, αξιοποιούνται οι δυνατότητες της Julia σε μετα-προγραμματισμό και ενδοσκοπήση (introspection) για τη συντακτική ανάλυση και μετατροπή του κώδικα που δόθηκε ως είσοδος.

Η μαθηματική περιγραφή του προτύπου μπορεί να δοθεί από τον χρήστη μέσω κώδικα με εύληπτο και απλό τρόπο:

Τμήμα Κώδικα 5.1: Julia Παράδειγμα ορισμού προτύπου-αστέρι

```

star_stencil = @def_stencil_expression c[0]D[x,y,z]
              + @sum(i, 1, 4, c[i]*(
                D[x+i,y,z] + D[x,y+i,z] + D[x,y,z+i] +
                D[x-i,y,z] + D[x,y-i,z] + D[x,y,z-i]))
  
```

Το πρώτο πράγμα που γίνεται όταν καλείται η μακρο-εντολή `@def_stencil` είναι να εκτελέσει τις εσωτερικές συναρτήσεις μακρο-εντολές και να αντικαταστήσει τις τιμές στην έκφραση που έχει δοθεί σαν όρισμα. Η έκφραση στη Julia είναι ένας τύπος δεδομένων που κρατάει κώδικα Julia και δίνει τις δυνατότητες ενδοσκοπήσης και μετα-προγραμματισμού. Η έκφραση έχει μορφή δέντρου, οπότε μέσω αναδρομής μπορούμε να φτάσουμε σε δείκτες πινάκων, σταθερούς αριθμούς και να τους τροποποιήσουμε. Η μακρο-εντολή `@sum` λειτουργεί όπως ο τελεστής `+`, ανοίγοντας την έκφραση και αντικαθιστώντας τους δείκτες με αριθμούς.

Συμβολικά Μαθηματικά Το δομικό στοιχείο συμβολικών μαθηματικών έχει δύο καθήκοντα. Το πρώτο και σημαντικότερο είναι να μετατρέψει τον κώδικα σε συμβολική μαθηματική έκφραση. Αυτό γίνεται πολύ εύκολα εκτελώντας τον τροποποιημένο κώδικα σε καθολική εμβέλεια (global scope). Αυτό σημαίνει πως η Julia θα ψάξει για έναν πίνακα D και έναν πίνακα c, τους οποίους θα έχουμε ήδη ορίσει να περιέχουν σύμβολα και συντελεστές αντίστοιχα.

Η δεύτερη δουλειά, η οποία είναι προαιρετική, είναι η τροποποίηση της συμβολικής έκφρασης για ομαδοποίηση βημάτων χρόνου. Ο τρόπος που γίνεται η ομαδοποίηση περιγράφεται αναλυτικά σε επόμενη παράγραφο. Στόχος είναι η δημιουργία μιας νέας μαθηματικής έκφρασης, η οποία όταν θα εφαρμόζεται μία φορά, θα έχει ως αποτέλεσμα πολλαπλά βήματα χρόνου. Η υλοποίηση περιλαμβάνει αναδρομική αντικατάσταση κάθε συμβόλου της έκφρασης με την ίδια την έκφραση μετατοπισμένη κατάλληλα.

Η βιβλιοθήκη συμβολικών μαθηματικών που χρησιμοποιήθηκε είναι η Symengine, η οποία είναι ένα "περιτύλιγμα" (wrapper) σε Julia γύρω από τη βιβλιοθήκη symengine σε C++.

Παραγωγή Κώδικα Αφού αναλυθεί ο κώδικας που έχει δώσει ο χρήστης ως είσοδο για να περιγράψει το πρότυπο, καθορίζονται οι αριθμητικές πράξεις που χρειάζονται. Ως πρότυπο για την δημιουργία της συνάρτησης πυρήνα χρησιμοποιήθηκε η τροποποιημένη υλοποίηση της NVIDIA που παρουσιάστηκε στο προηγούμενο κεφάλαιο. Το πρότυπο μπορεί να διασπαστεί στα εξής τμήματα:

- Αρχικοποίηση. Γίνεται η κατανομή μνήμης, ορισμός υποπινάκων και αρχικοποίηση καταχωρητών.
- Βρόγχος επανάληψης κατά z άξονα:
 - Μεταφορά δεδομένων στη μεριζόμενη μνήμη
 - Αριθμητικές πράξεις.
 - Αποθήκευση αποτελεσμάτων στην καθολική μνήμη.

Η βιβλιοθήκη για συμβολικά μαθηματικά είναι πολύ χρήσιμη για το κομμάτι των αριθμητικών πράξεων. Για κάθε σύμβολο που μπορεί να περιλαμβάνεται στην έκφραση αναζητείται και υπολογίζεται ο συντελεστής και η σχετική θέση του στον τρισδιάστατο χώρο ως προς το κέντρο του προτύπου. Σε κάθε σύμβολο που έχει μη μηδενικό συντελεστή αναλογεί μια αριθμητική πράξη. Ο καταχωρητής στον οποίο θα αποθηκευτεί το αποτέλεσμα εξάγεται από τη θέση στον χώρο.

Αφού ο κώδικας έχει παραχθεί, δίνεται ως όρισμα στην βιβλιοθήκη SyntaxTree όπου και μετατρέπεται σε συνάρτηση που μπορεί να κληθεί.

Σύστημα Εκτέλεσης Το σύστημα εκτέλεσης είναι υπεύθυνο για την εκτέλεση της συνάρτησης πυρήνα σε μία ή περισσότερες κάρτες γραφικών, ή για τον υπολογισμό προτύπου μέσω FFT. Για μία κάρτα γραφικών, το σύστημα αλλάζει το μέγεθος του πίνακα ανάλογα με την ομαδοποίηση βημάτων χρόνου, μεταφέρει τα δεδομένα στην κάρτα και καλεί τη συνάρτηση πυρήνα όσες φορές χρειάζεται. Για περισσότερες κάρτες γραφικών, το σύστημα πρέπει επιπλέον να χωρίσει τα δεδομένα, έχοντας επικαλυπτόμενα τμήματα ανάλογα με τον αριθμό βημάτων που γίνονται σε κάθε κάρτα πριν επικοινωνήσουν

μεταξύ τους. Για τον υπολογισμό προτύπου μέσω συνέλιξης στο πεδίο της συχνότητας γίνονται παρόμοιες διαδικασίες με αυτές για τη μία κάρτα γραφικών. Η επιλογή για FFT προτείνεται από το σύστημα και η τελική επιλογή γίνεται από τον χρήστη.

5.4 Βελτιστοποιήσεις

5.4.1 Καθολική και Μεριζόμενη μνήμη

Οι μέθοδοι βελτιστοποίησης που εφαρμόζονται στη συνάρτηση πυρήνα περιγράφονται στην προηγούμενη παράγραφο. Ως υπόδειγμα χρησιμοποιήθηκε η τροποποιημένη υλοποίηση της NVIDIA από τον Mo κ.α και επομένως οι ίδιες τεχνικές χρησιμοποιούνται για την καλύτερη αξιοποίηση της μνήμης. Η αποδοτικότητα της καθολικής μνήμης είναι όσο πιο ψηλά γίνεται, ενώ η απόδοση της μεριζόμενης μνήμης είναι 100%.

5.4.2 Ξετύλιγμα βρόγχων επανάληψης

Οι αριθμητικές πράξεις στους υπολογισμούς προτύπων μπορούν να γίνουν με επαναληπτικό τρόπο κατά μήκος της διαμέτρου, όπως γίνεται με τον τελεστή αθροίσματος στο παράδειγμα της λαπλασιανής. Υπάρχουν πρότυπα που δεν εμφανίζουν περιοδική δομή και επομένως δε μπορούν να υπολογιστούν με τη βοήθεια επαναληπτικού βρόγχου. Αυτός είναι καθοριστικός λόγος για τον οποίο οι επαναληπτικοί βρόγχοι ξετυλίγονται τελείως.

Τμήμα Κώδικα 5.2: Παράδειγμα ξεδιπλωμένου επαναληπτικού βρόγχου στον παραγόμενο κώδικα σε Julia.

```
@inbounds temp = tile[txr + -1, tyr + 0]
current += cfarr[1] * temp
@inbounds temp = tile[txr + 0, tyr + -1]
current += cfarr[1] * temp
@inbounds temp = tile[txr + 0, tyr + 0]
current += temp
infront1 += cfarr[1] * temp
behind1 += cfarr[1] * temp
@inbounds temp = tile[txr + 0, tyr + 1]
current += cfarr[1] * temp
@inbounds temp = tile[txr + 1, tyr + 0]
current += cfarr[1] * temp
```

Αυτό το επιθετικό ξετύλιγμα βρόγχων επανάληψης έχει πλεονεκτήματα και μειονεκτήματα [23]. Στα πλεονεκτήματα συγκαταλέγονται μειωμένος αριθμός εντολών, λόγω της αφαίρεσης εντολών ελέγχου στους βρόγχους επανάληψης, αυξημένη δυνατότητα παραλληλισμού σε επίπεδο εντολών (Instruction Level Parallelism) και πιο αποδοτική χρήση μεριζόμενης μνήμης. Στο παραπάνω παράδειγμα, σε τρεις από τις αριθμητικές πράξεις χρησιμοποιείται το ίδιο στοιχείο από τη μεριζόμενη μνήμη. Άμα χρησιμοποιούνταν βρόγχοι επανάληψης, οι τρεις αυτές πράξεις δε θα μπορούσαν να είναι συνεχόμενες και το ίδιο στοιχείο θα διαβάζονταν τρεις φορές. Όσον αφορά τα μειονεκτήματα, αυξάνεται η πίεση στους καταχωρητές, αφού κάθε αποτέλεσμα χρειάζεται

ξεχωριστό καταχωρητή, με αποτέλεσμα να μην αξιοποιούνται αποδοτικά οι πόροι της κάρτας γραφικών.

5.4.3 Ομαδοποίηση Βημάτων Χρόνου

Ο τρόπος με τον οποίο προηγούμενες έρευνες υλοποιούν την ομαδοποίηση βημάτων χρόνου, είναι να κάνουν πολλαπλές επαναλήψεις στα δεδομένου που έχουν διαβαστεί σε κρυφή/γρήγορη μνήμη για να υπολογίσουν πολλαπλά βήματα χρόνου. Αυτός ο τρόπος δε μπορεί να εφαρμοστεί αποδοτικά σε τρισδιάστατα πρότυπα και καθόλου σε μη ολιστικές προσεγγίσεις. Η βασική ιδέα, που εφαρμόζεται σε αυτήν την πλατφόρμα, είναι να δημιουργηθεί ένα καινούριο πρότυπο, που όταν εφαρμοστεί μία φορά, θα έχει το ίδιο αποτέλεσμα με το να εφαρμοστεί το αρχικό πρότυπο περισσότερες φορές.

Η εξίσωση για το δισδιάστατο πρότυπο-αστέρι είναι:


$$D^{t+1}[x, y] = c[0]D^t[x, y] + \sum_{i=1}^n c[i]D^t[x + i, y] + D^t[x - i, y] + D^t[x, y + i] + D^t[x, y - i]) \quad (5.1)$$

Για το επόμενο βήμα χρόνου, t αντικαθίσταται με $t+1$

$$D^{t+2}[x, y] = c[0]D^{t+1}[x, y] + \sum_{i=1}^n c[i]D^{t+1}[x + i, y] + D^{t+1}[x - i, y] + D^{t+1}[x, y + i] + D^{t+1}[x, y - i]) \quad (5.2)$$

Αν αντικαταστήσουμε την 5.1 στην 5.2, βρίσκουμε την τιμή D^{t+2} , χρησιμοποιώντας μόνο τις τιμές D^t . Αυτή η διαδικασία μπορεί να εφαρμοστεί m φορές για να βρεθούν οι τιμές D^{t+m} . Το καινούριο πρότυπο θα έχει μέγιστη διάμετρο $m * n$ και οι παραπάνω αριθμητικές πράξεις εξαρτώνται από το σχήμα του προτύπου.

Τα ίδια ισχύουν και για τα τρισδιάστατα πρότυπα. Με τη μη ολιστική προσέγγιση, η επιρροή της ομαδοποίησης βημάτων χρόνου στη μεριζόμενη μνήμη είναι ίδια με αυτή στα δισδιάστατα πρότυπα, με τη διαφορά ότι χρειάζονται επιπλέον καταχωρητές. Και με αυτήν την προσέγγιση γίνονται περιττοί υπολογισμοί. Οι περιττοί υπολογισμοί δε βρίσκονται στην ανανέωση τιμών του στεφανιού, αλλά ως επιπλέον πράξεις για κάθε στοιχείο. Ένα δισδιάστατο πρότυπο αστέρι χρειάζεται $2*5 = 10$ πράξεις για δύο βήματα χρόνου με επανάληψη και 11 με ομαδοποίηση βημάτων χρόνου. Για τρισδιάστατο αστέρι, από $2 * 9 = 18$ πηγαίνει σε 25 πράξεις.



Σχήμα 5.2: Δισδιάστατο πρότυπο αστέρι με ομαδοποίηση βημάτων χρόνου.


5.5 Πολλαπλές Κάρτες Γραφικών

Για την αξιοποίηση πολλαπλών καρτών γραφικών πρέπει να λυθούν τρία προβλήματα.

- Πώς θα διαχωριστούν τα δεδομένα.
- Πώς θα γίνει η επικοινωνία του ανανεωμένου επικαλυπτόμενου τμήματος.
- Πόσα βήματα χρόνου θα γίνουν σε κάθε κάρτα πριν επικοινωνήσουν μεταξύ τους.

Η απάντηση στο πρώτο πρόβλημα είναι να χωριστούν τα δεδομένα κατά τον z άξονα, δηλαδή κατά τον άξονα που μεταβάλλεται αργότερα καθώς κινούμαστε στα δεδομένα στη φυσική μνήμη. Το πλεονέκτημα αυτής της προσέγγισης είναι η απλότητά της και το γεγονός ότι κάθε τμήμα θα είναι συνεχόμενο στη μνήμη. Αν υπάρχουν διαφορετικές σε απόδοση κάρτες γραφικών, τα δεδομένα θα διασπαστούν αναλόγως.

Η παραπάνω προσέγγιση βοηθάει και στο δεύτερο πρόβλημα, της επικοινωνίας. Τα επικαλυπτόμενα τμήματα θα είναι και αυτά συνεχόμενα στη φυσική μνήμη, και επομένως η μεταφορά τους από τη μία κάρτα στην άλλη θα είναι εύκολη και γρήγορη, είτε έχουμε απευθείας μεταφορά μεταξύ των καρτών, είτε μέσω του επεξεργαστή, είτε αν έχουμε διανεμημένο σύστημα. Ο λόγος που χρειάζονται επικαλυπτόμενα τμήματα οφείλεται στο "στεφάνι" που έχει αναφερθεί προηγουμένως. Στη συγκεκριμένη περίπτωση, χρησιμοποιείται απευθείας επικοινωνία μεταξύ καρτών (peer to peer).



Σχήμα 5.3: Οπτικοποίηση διάσπασης δεδομένων σε πολλαπλές κάρτες γραφικών.

Το τρίτο πρόβλημα σκοπεύει στη μείωση του σταθερού κόστους επικοινωνίας, μειώνοντας τον αριθμό τους, πραγματοποιώντας περισσότερα από ένα βήματα χρόνου πριν οι κάρτες γραφικών επικοινωνήσουν. Όσο περισσότερα είναι αυτά τα βήματα χρόνου, τόσο αυξάνεται η χρήση μνήμης και ο αριθμός των περιττών πράξεων. Για να βελτιωθεί η απόδοση πρέπει οι περιττοί υπολογισμοί να κοστίζουν λιγότερο από το σταθερό κόστος επικοινωνίας. Επομένως, αυτή η μέθοδος εξαρτάται άμεσα από την απόδοση της κάθε κάρτας γραφικών.

Τελικά η πορεία που ακολουθείται είναι:

1. Διαχωρισμός δεδομένων και μεταφορά στις κάρτες γραφικών
2. Εκτέλεση ενός ή περισσότερων βημάτων χρόνου
3. Ανταλλαγή επικαλυπτόμενου τμήματος δεδομένων σε κάρτες που έχουν γειτονικά μέρη.

5.6 Υπολογισμός προτύπου με FFT

Όσο αυξάνεται το μέγεθος, ακτίνα και πυκνότητα του προτύπου, τόσο αυξάνονται οι απαιτήσεις σε πόρους και ο χρόνος εκτέλεσης. Μεγάλα πρότυπα χρειάζονται περισσότερους καταχωρητές, περισσότερη μεριζόμενη μνήμη και δε χρησιμοποιούνται αποδοτικά όλοι οι πόροι της κάρτας γραφικών. Για ακόμα μεγαλύτερα μεγέθη (ακτίνα > 32 στοιχεία) οι πόροι δεν αρκούν για να εκτελεστεί ο υπολογισμός του προτύπου. Μια επιλογή θα ήταν η διάσπαση του προτύπου σε διαφορετικές συναρτήσεις πυρήνα, αλλά μέσα από εκτελέσεις αποδείχθηκε ότι είναι τουλάχιστον 4 φορές πιο αργό. Παρόλου που το πρότυπο διασπάται στη μέση, οι απαιτήσεις σε μνήμη δε γίνονται μισές και απαιτείται συγχρονισμός διαφορετικών συναρτήσεων-πυρήνα, που γίνεται σε επίπεδο επεξεργαστή.

Μία προσέγγιση που μπορεί να λύσει το πρόβλημα των μεγάλων προτύπων, είναι ο υπολογισμός του στην συχνότητα μέσω FFT. Ένα απλό πρότυπο είναι παρόμοιο με τη συνέλιξη, με τη διαφορά να βρίσκεται πως σε συνήθεις εφαρμογές εφαρμόζεται

πολλές φορές στα δεδομένα σε σχέση με την συνέλιξη. Η συνέλιξη χρησιμοποιείται σε εφαρμογές επεξεργασίας ψηφιακής εικόνας και σήματος, όπως υπολογισμός της συσχέτισης ή εφαρμογή φίλτρου Gauss [24] και εφαρμόζεται λίγες φορές.

Για παράδειγμα, ο τύπος της δισδιάστατης συνέλιξης $f(x, y) = \sum_i \sum_j g(i, j) * h[x - i, y - j]$ μετατρέπεται σε περιγραφή προτύπου αν θεωρήσουμε τη συνάρτηση h ως τα δεδομένα εισόδου την χρονική στιγμή t , τη συνάρτηση f ως τα δεδομένα εισόδου την χρονική στιγμή $t + 1$ και την g ως γειτονιά του προτύπου.

Το FLCC (Fast Library for Convolution and Correlation [25]) είναι μία βιβλιοθήκη που στοχεύει στην επιτάχυνση του υπολογισμού της συνέλιξης και των τοπικών συντελεστών συσχέτισης με τη βοήθεια καρτών γραφικών. Συγκεκριμένα για τη συνέλιξη, παρουσιάζεται μια υλοποίηση που χρησιμοποιεί FFT και αναλύονται τα μεγέθη των δεδομένων για τα οποία συμφέρει ο FFT από την επαναληπτική μέθοδο. Για μεγάλες εικόνες και για πρότυπο με πλάτος μεγαλύτερο από 16 πίξελ, η επιτάχυνση αγγίζει το $\times 10$. Η ίδια προσέγγιση μπορεί να χρησιμοποιηθεί όχι μόνο για μεγάλα πρότυπα, αλλά και για αυτά που παράγονται από την ομαδοποίηση βημάτων χρόνου.

Η υλοποίηση περιλαμβάνει μεταφορά των δεδομένων και του προτύπου στο πεδίο της συχνότητας, πολλαπλασιασμός στοιχείο με στοιχείο και επαναφορά του αποτελέσματος στο πεδίο του χρόνου. Όλα τα βήματα αυτά λαμβάνουν μέρος στην κάρτα γραφικών, οπότε η μεταφορά δεδομένων από τον επεξεργαστή στην κάρτα και αντίστροφα είναι το ίδιο με την περίπτωση της επαναληπτικής υλοποίησης σε μία κάρτα γραφικών.

Επιπροσθέτως, αξιοποιείται η ομαδοποίηση βημάτων χρόνου για να υπολογιστούν περισσότερα βήματα χρόνου με μία εφαρμογή της παραπάνω διαδικασίας. Παρόλο που το καινούριο πρότυπο έχει πολλαπλάσια ακτίνα, οι επιπλέον υπολογισμοί που απαιτεί ο FFT δεν αυξάνονται τόσο γρήγορα, καθώς η ακτίνα του προτύπου απλά προστίθεται στο μέγεθος των δεδομένων εισόδου. Επίσης το καινούριο πρότυπο έχει μεγαλύτερη πυκνότητα, το οποίο όμως δεν επηρεάζει την ταχύτητα αφού δεν επηρεάζεται από τον αριθμό των μηδενικών η διαδικασία μετατροπής δεδομένων στη συχνότητα ή ο πολλαπλασιασμός στοιχείων.

Η μαθηματική ανάλυση της εφαρμογής συνέλιξης στο πεδίο της συχνότητας είναι γνωστή και περιγράφεται αναλυτικά στη διπλωματική διατριβή όπου και υλοποιείται αναλυτικά η βιβλιοθήκη FLCC [26].


Κεφάλαιο 6

Άποτελέσματα

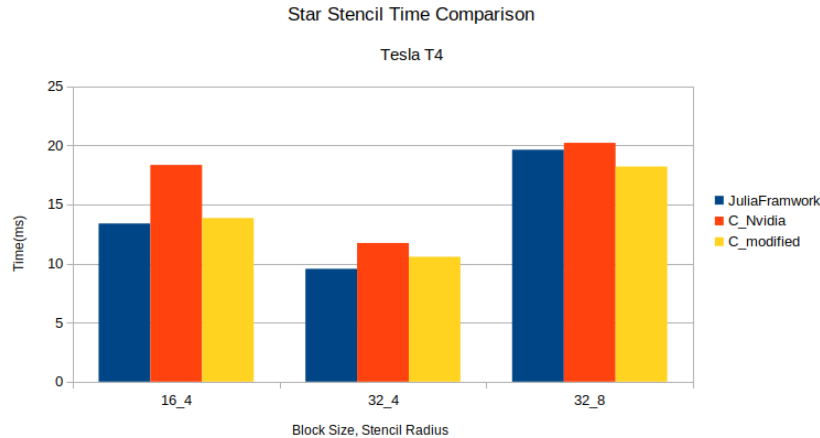
6.1 Αποτελέσματα απόδοσης

Οι μετρήσεις που συλλέχθηκαν για την απόδοση της πλατφόρμας πρέπει να συγκριθούν με υπάρχουσες υλοποιήσεις που είναι αποδεδειγμένα υψηλής απόδοσης. Για αυτόν τον σκοπό, επιλέχθηκε η υλοποίηση της NVIDIA, για την οποία υπάρχει δημοσιευμένος κώδικας στην έρευνα. Επίσης, χρησιμοποιείται και η τροποποιημένη υλοποίηση της NVIDIA, η οποία υλοποιήθηκε από το μηδέν σε C καθώς ο Mo κ.α δεν παρέχουν κώδικα στη δημοσίευσή τους.

Εφόσον η συνάρτηση πυρήνα της NVIDIA για πεπερασμένες διαφορές μπορεί να υπολογίσει μόνο πρότυπο τύπου αστέρι, όλες οι συγκρίσεις έγιναν για αυτόν τον τύπο. Οι μετρήσεις έγιναν σε κάρτες γραφικών Tesla T4 και Tesla K80 για διάφορα μεγέθη ακτίνας προτύπου και ομάδων νημάτων.



Σχήμα 6.1: Σύγκριση της Julia με τη C για πρότυπο-αστέρι.



Σχήμα 6.2: Σύγκριση της Julia με τη C για πρότυπο-αστέρι.


Για ομάδα νημάτων 32×32 η υλοποίηση σε Julia είναι πάντα πιο γρήγορη από την υλοποίηση της NVIDIA και ορισμένες φορές πιο γρήγορη από την τροποποιημένη υλοποίηση γραμμένη σε C. Τα αποτελέσματα δείχνουν ότι επιλογή της συνάρτησης-πυρήνα, που χρησιμοποιήθηκε σαν πρότυπο ήταν σωστή. Ακόμα, φαίνεται ότι η απόδοση της Julia ως γλώσσα είναι καλή και ότι η παραγωγή κώδικα δουλεύει σωστά.

Όπως και στο 3ο κεφάλαιο, οι μετρικές της κάρτας γραφικών είναι ολόιδιες για ίδιες υλοποιήσεις. Η συνάρτηση πυρήνα που παράγει η πλατφόρμα εκμεταλλεύεται στο 100% τη ρυθμαπόδοση της μεριζόμενης μνήμης και στο μέγιστο δυνατό τη ρυθμαπόδοση της καθολικής.

Έχοντας εδραιώσει τη σωστή λειτουργία και καλή απόδοση της πλατφόρμας για τη βασική περίπτωση, ακολουθεί η αξιολόγηση των μεθόδων βελτιστοποίησης πάνω σε αυτή.


6.1.1 Ομαδοποίηση στον χρόνο

Οι βασικοί παράγοντες που επηρεάζουν την απόδοση αυτής της μεθόδου βελτιστοποίησης είναι η πυκνότητα του προτύπου, η αρχική του ακτίνα και ο αριθμός των βημάτων χρόνου που ομαδοποιούνται. Τρεις τύποι προτύπου επιλέχθηκαν, οι οποίοι έχουν διαφορετική πυκνότητα, άθροισμα ροών (flux summation), αστέρι και πυκνό πρότυπο, από μικρότερη σε μεγαλύτερη πυκνότητα.

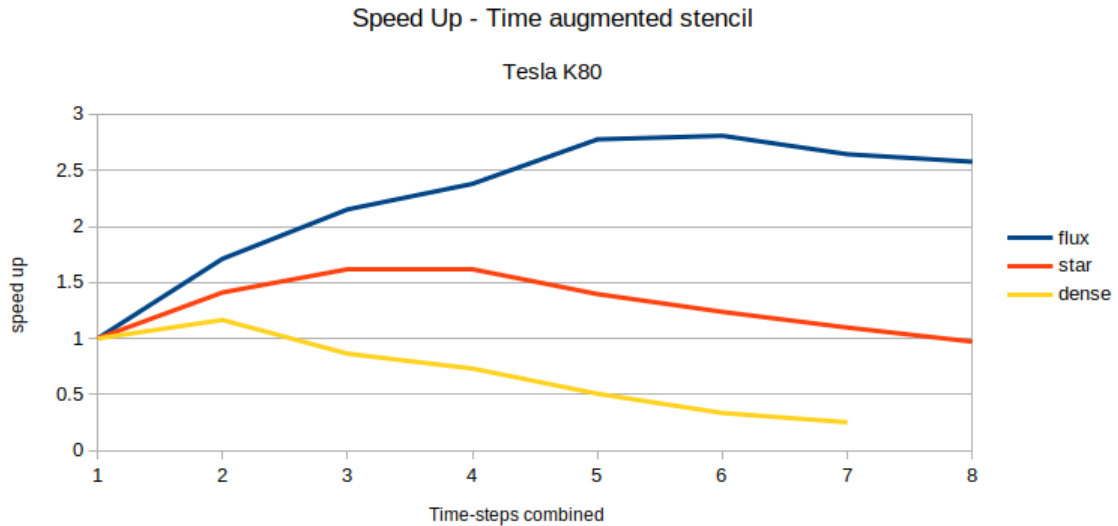


Σχήμα 6.3: 3 τύποι προτύπου με διαφορετικές πυκνότητες. 1) Άθροισμα ροών 2) Αστέρι 3) Πυκνό

Οι εκτελέσεις για μετρήσεις έγιναν στις κάρτες γραφικών Tesla T4 και Tesla K80. Τα γραφήματα στο σχήμα 6.3 δείχνουν την επιτάχυνση που επιφέρει η ομαδοποίηση βημάτων χρόνου σε σχέση με τον χρόνο που χρειάζεται το αρχικό πρότυπο για τα ίδια βήματα. Σε όλες τις περιπτώσεις τα αρχικά πρότυπα έχουν ακτίνα ένα, όπως και στο σχήμα 6.2.



Σχήμα 6.4: Επιτάχυνση με ομαδοποίηση βημάτων χρόνου.



Σχήμα 6.5: Επιτάχυνση με ομαδοποίηση βημάτων χρόνου.

Από τις μέτρησεις φαίνεται πως το πυκνό πρότυπο δεν επωφελείται από την ομαδοποίηση βημάτων χρόνου. Οι εκτελέσεις με ομαδοποίηση είναι πιο αργές από το αρχικό πρότυπο, εκτός από μία περίπτωση που πετυχαίνει $1.16\times$ επιτάχυνση για δύο βήματα χρόνου ομαδοποιημένα.

Στο άλλο άκρο, όσον αφορά την πυκνότητα, το πρότυπο αθροίσματος ροών έχει την καλύτερη επιτάχυνση με ομαδοποίηση βημάτων χρόνου σε σχέση με τα άλλα δύο. Για κάθε αριθμό βημάτων χρόνου υπάρχει θετική επιτάχυνση, η οποία αγγίζει το $2.8\times$ και φαίνεται ότι υπάρχει προοπτική για επιτάχυνση και σε περισσότερα από 8 βήματα χρόνου.

Το ενδιαφέρον όμως επικεντρώνεται κυρίως στο πρότυπο-αστέρι, που έχει ενδιαμέση πυκνότητα από τα άλλα δύο και χρησιμοποιείται πιο συχνά, όπως στις πεπερασμένες διαφορές και σε κυτταρικά αυτόματα. Η καλύτερη επιτάχυνση είναι $1.65\times$ για την Tesla K80 και $1.45\times$ για την Tesla T4. Μέχρι 5 βήματα χρόνου η επιτάχυνση αυξάνεται, με την καλύτερη να βρίσκεται για 4 βήματα. Μετά από 5 βήματα χρόνου η επιτάχυνση μειώνεται ενώ για 7 είναι αρνητική.

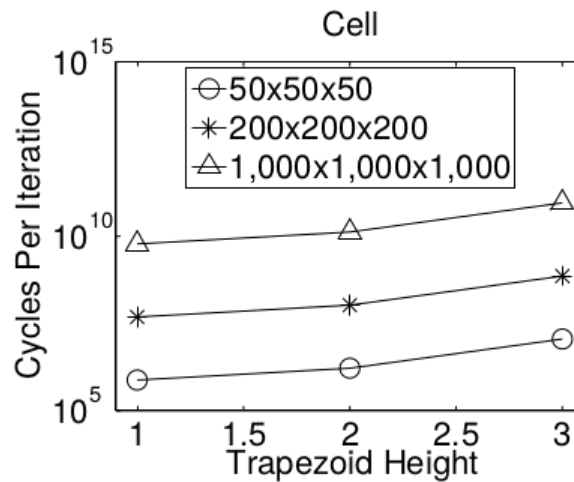
Για πρότυπο-αστέρι με ακτίνα 2, η μέγιστη επιτάχυνση είναι $1.15\times$ για 2 βήματα χρόνου και καθόλου για τα υπόλοιπα. Για μεγαλύτερη ακτίνα δεν υπάρχει καθόλου επιτάχυνση καθώς οι πόροι που απαιτούνται για μνήμη είναι πολλοί και δεν επιτρέπουν την αποδοτική χρήση των υπόλοιπων πόρων της κάρτας γραφικών.

Για να αξιολογηθεί το πόσο καλή ή όχι είναι η επιτάχυνση της ομαδοποίησης βημάτων χρόνου που χρησιμοποιεί η πλατφόρμα, θα συγκριθεί με υπάρχουσες έρευνες για ομαδοποίηση βημάτων χρόνου με επαναληπτική προσέγγιση. Ο Meng κ.α. [1] μελετούν την επιρροή του μεγέθους του στεφανιού στην απόδοση, το οποίο αυξάνεται με τον αριθμό βημάτων χρόνου που ομαδοποιούνται, ενώ ο Holewinski κ.α. [2] χρησιμοποιούν τη μέθοδο της ομαδοποίησης στην αυτοματοποιημένη πλατφόρμα που παρουσιάζουν. Οι δύο έρευνες επικεντρώνονται σε δισδιάστατα πρότυπα, αλλά παρουσιάζουν την εφαρμογή της μεθόδου και σε τρισδιάστατα.


Το τρισδιάστατο πρότυπο που χρησιμοποιεί ο Meng κ.α. προέρχεται από τα κυτταρι-

κά αυτόματα και χρησιμοποιείται από το Παιχνίδι της Ζωής του Conway [27]. Είναι ολόιδιο με το πρότυπο-αστέρι ακτίνας 1, με τη μόνη διαφορά να βρίσκεται πως αντί για προσθέσεις έχει και λογικές πράξεις. Η σύγκριση είναι έγκυρη αν μείνει στην επιτάχυνση και όχι στους απόλυτους χρόνους εκτέλεσης.

Ο Holewinski κ.α. χρησιμοποιούν το τρισδιάστατο πρότυπο-αστέρι ακτίνας 1 για τη μέθοδο Jacobi.



Σχήμα 6.6: Meng κ.α. [1] Ομαδοποίηση βημάτων χρόνου για διάφορα μεγέθη δεδομένων εισόδου. Το ύψος του τραπεζίου συμβολίζει τον αριθμό βημάτων χρόνου που ομαδοποιούνται.




Σχήμα 6.7: Holewinski κ.α. [2] Απόδοση σε διαφορετικές κάρτες γραφικών, με και χωρίς ομαδοποίηση βημάτων χρόνου. Μόνο το Jacobi 3D είναι τρισδιάστατο.


Είναι προφανές πως για τα τρισδιάστατα πρότυπα δεν επιτυγχάνεται καμία επιτάχυνση. Μάλιστα, για το κυτταρικό αυτόματο η απόδοση μειώνεται αρκετά με την εφαρμογή της

ομαδοποίησης βημάτων χρόνου. Συγκρίνοντας την απόδοση της πλατφόρμας που έχει διαφορετική προσέγγιση για την ομαδοποίηση βημάτων χρόνου με τις δύο έρευνες, η 1.5× επιτάχυνση φαίνεται μεγάλη βελτίωση, το οποίο είναι ενθαρρυντικό για περαιτέρω έρευνα πάνω στην προσαρμογή για μεγαλύτερα πρότυπα.

Παρόλο που η πλατφόρμα δημιουργήθηκε έχοντας υπόψη κυρίως τα τρισδιάστατα πρότυπα, είναι πολύ εύκολο να εκτελεστούν δισδιάστατα πρότυπα και να εφαρμοστεί η ομαδοποίηση σε αυτά. Για την σύγκριση στο δισδιάστατο κομμάτι θα χρησιμοποιηθεί το πρότυπο αστερί με ακτίνα 1 (5 σημεία) και 2 (9 σημεία), το οποίο εφαρμόζεται στη δισδιάστατη μέθοδο Jacobi και χρησιμοποιείται στις μετρήσεις του Holewinski κ.α., όπου η ομαδοποίηση εφαρμόζεται επιτυχώς.



Σχήμα 6.8: Ομαδοποίηση βημάτων χρόνου σε πρότυπο-αστέρι.




Σχήμα 6.9: Holewinski κ.α. [2] Ομαδοποίηση βημάτων χρόνου για δισδιάστατο Jacobi

Ο Holewinski κ.α καταφέρνουν την καλύτερη επιτάχυνση για 6 βήματα χρόνου, με χρόνο 0.4 επί του αρχικού. Αντίστοιχα, η πλατφόρμα σε Julia έχει την καλύτερη επιτάχυνση στο 5ο βήμα χρόνου, με χρόνο 0.43 επί του αρχικού. Το γεγονός ότι η καλύτερη επιτάχυνση βρίσκεται για διαφορετικό βήμα χρόνου δεν έχει σημασία για την τελική απόδοση. Η διαφορά σε επιτάχυνση μεταξύ των δύο προσεγγίσεων ομαδοποίησης χρόνου είναι πολύ μικρή και αποδεικνύει την αποτελεσματικότητα της νέας μεθόδου.

6.1.2 Πολλαπλές Κάρτες Γραφικών

Οι εκτελέσεις για την μέτρηση της απόδοσης υπολογισμών προτύπων σε πολλαπλές κάρτες γραφικών έγιναν σε 4 Tesla K80. Επιπλέον μελετήθηκε αν η εκτέλεση περισσότερων βημάτων χρόνου πριν την ανταλλαγή δεδομένων μεταξύ των καρτών γραφικών βελτιώνει την απόδοση. Αυτό είχε προταθεί από τον Micikevicius [14] ο οποίος υποψιάζοταν πως θα υπάρχει βελτίωση για μικρά πρότυπα.


Στο επόμενο γράφημα φαίνεται απόδοση σε πολλαπλές κάρτες γραφικών για διαφορετικά μεγέθη δεδομένων εισόδου με διαφορετική αναλογία στο μήκος των διαστάσεων.



Σχήμα 6.10: Πορεία της επιτάχυνσης για διαφορετική αναλογία στο μήκος των διαστάσεων. Πρότυπο-αστέρι με ακτίνα 8

Στο γράφημα παρατηρείται μια ελαφριά τάση για μεγαλύτερη επιτάχυνση όσο μεγαλώνει και το μήκος του z άξονα σε σχέση με τους x y. Αυτό ήταν αναμενόμενο, καθώς όσο μεγαλύτερα είναι τα μήκη των διαστάσεων x y τόσο μεγαλύτερα τμήματα μνήμης χρειάζεται να μεταφερθούν σε σχέση με τους υπολογισμούς. Βέβαια η διαφορά είναι αρκετά μικρή και δεν αποτελεί προτεραιότητα να αλλάξει ο τρόπος με τον οποίο χωρίζονται τα δεδομένα στις κάρτες γραφικών.

Στη συνέχεια μελετάται η πορεία της επιτάχυνσης για διαφορετικές ακτίνες.




Σχήμα 6.11: Επιτάχυνση για διαφορετικές ακτίνες. Πρότυπο-αστέρι

Η πορεία της επιτάχυνσης σε σχέση με την ακτίνα είναι σχετικά σταθερή. Για 2 κάρτες γραφικών η επιτάχυνση είναι σταθερή $2\times$ και για 4 κάρτες είναι ομοίως σταθερή $3.5\times$. Η μη-γραμμική αύξηση της επιτάχυνσης σε σχέση με τον αριθμό των καρτών γραφικών οφείλεται στις επικοινωνίες μεταξύ των καρτών όπου υπάρχουν αδρανείς κάρτες που περιμένουν να ολοκληρωθεί η μεταφορά δεδομένων στις άλλες, κάτι το οποίο δεν εμφανίζεται για 2 κάρτες γραφικών.

Η τακτική να πραγματοποιούνται περισσότερα βήματα χρόνου πριν τη μεταφορά δεδομένων μεταξύ των καρτών δεν ήταν αποτελεσματική. Η καλύτερη επιτάχυνση που παρατηρήθηκε ήταν αμελητέα, $1.06\times$. Για μεγάλες ακτίνες και πολλά βήματα χρόνου δεν υπήρχε καμία βελτίωση ή υπήρχε επιβράδυνση $2\times$. Όσο περισσότερα βήματα χρόνου γίνονται σε κάθε κάρτα πριν την επικοινωνία, τόσο μεγαλύτερο είναι το επικαλυπτόμενο τμήμα που πρέπει να υπολογιστεί και να μεταφερθεί. Έτσι, παρόλο που το σταθερό κόστος επικοινωνίας μειώθηκε πραγματοποιώντας λιγότερες σε αριθμό επικοινωνίες, ο όγκος των δεδομένων που μεταφέρεται παραμένει ίδιος και αυξάνονται τα δεδομένα στα οποία γίνονται υπολογισμοί. Το σταθερό κόστος επικοινωνίας είναι πολύ μικρό σε σχέση με τους επιπλέον υπολογισμούς, οπότε δεν παρατηρείται κάποια επιτάχυνση με αυτή τη μέθοδο.


6.1.3 Υπολογισμός προτύπων με FFT

Αρχικά, γίνεται σύγκριση της επαναληπτικής μεθόδου με τον FFT, σε 2 τριδιάστατα πρότυπα με διαφορετικές πυκνότητες για διαφορετικά μεγέθη. Οι γραμμές στο γράφημα που αναφέρονται στον FFT, έχουν διαφορετική ομαδοποίηση βημάτων χρόνου. Ο αριθμός δίπλα στο fft δηλώνει τη νέα ακτίνα του προτύπου με ομαδοποίηση. Για παράδειγμα, για ακτίνα 4, το fft_32 εκτελεί 8 βήματα χρόνου με ένα πέρασμα. Όλες οι γραμμές του σχήματος είναι κανονικοποιημένες και αντιστοιχούν στον χρόνο που χρειάζεται ένα βήμα.



Σχήμα 6.12: Επιτάχυνση με FFT για διαφορετικές ακτίνες. Πρότυπο-αστέρι

Το πρότυπο-αστέρι δεν παρουσιάζει καμία βελτίωση. Η επαναληπτική μέθοδος είναι αρκετά γρήγορη ακόμα και για μεγάλη ακτίνα καθώς το πρότυπο αυτό είναι πολύ αραιό, με πυκνότητα μόλις 3% των στοιχείων του κύβου που το περικλείει για ακτίνα 4. Μόνο για ακτίνα 1 και ομαδοποίηση 48 βημάτων χρόνου παρατηρείται μια μικρή επιτάχυνση $\times 1.18$




Σχήμα 6.13: Επιτάχυνση με FFT για διαφορετικές ακτίνες. Πυκνό πρότυπο

Για το πυκνό πρότυπο τα αποτελέσματα είναι πολύ καλύτερα. Για κάθε μέγεθος ακτίνας, υπάρχει εκτέλεση του FFT που είναι πιο γρήγορη. Σε αντίθεση με το αστέρι, το πυκνό πρότυπο έχει πυκνότητα 100%.

Ένα σημαντικό συμπέρασμα που προκύπτει από τα γραφήματα, είναι πως όσο μεγαλύτερη είναι η ομαδοποίηση βημάτων χρόνου, τόσο βελτιώνεται η απόδοση του FFT για


ένα βήμα. Αυτό ήταν αναμενόμενο, καθώς , όπως αναφέρθηκε και στο προηγούμενο κεφάλαιο, ενώ πολλαπλασιάζεται η ακτίνα του προτύπου , οι επιπλέον υπολογισμοί δεν ακολουθούν την ίδια αυξητική συμπεριφορά και υπολογίζονται πολλαπλάσια βήματα χρόνου.

Για να γίνει αντιληπτό το όριο στο οποίο η μέθοδος στη συχνότητα είναι πιο γρήγορη από την επαναληπτική, χρειάζεται να γίνει η εφαρμογή τους σε πρότυπα με ενδιάμεσες τιμές πυκνότητας.




Σχήμα 6.14: Επιτάχυνση με FFT για διαφορετικές πυκνότητες προτύπων


Όπως και στην περίπτωση της ομαδοποίησης βημάτων χρόνου, έτσι και εδώ θα αξιολογηθεί η μέθοδος επιτάχυνσης και για διδιάστατα πρότυπα.



Σχήμα 6.15: Επιτάχυνση με FFT για διαφορετικές ακτίνες. Δισδιάστατο πρότυπο-αστέρι



Σχήμα 6.16: Επιτάχυνση με FFT για διαφορετικές ακτίνες. Δισδιάστατο πυκνό πρότυπο.



Σχήμα 6.17: Επιτάχυνση με FFT για διαφορετικές πυκνότητες προτύπων

Ομοίως με το τρισδιάστατο πρότυπο, παρατηρείται επιτάχυνση μόνο για ακτίνα 1. Σε αυτήν την περίπτωση η επιτάχυνση είναι μεγαλύτερη, $\times 1.9$ και $\times 2.1$ για 48 και 64 ομαδοποιημένα βήματα χρόνου. Για διαφορετικές πυκνότητες, φαίνεται η ίδια συμπεριφορά με το τρισδιάστατο πρότυπο, με τη διαφορά πως το σημείο που ο FFT είναι πιο γρήγορος εμφανίζεται για μεγαλύτερη πυκνότητα.

Παρατηρώντας τα αποτελέσματα του FLCC [25] για την συνέλιξη, το σημείο πέρα από το οποίο συμφέρει ο FFT είναι για συνέλιξη με πρότυπο μεγέθους 12×12 , που αναλογεί σε πρότυπο ακτίνας 6. Στην περίπτωση του πυκνού προτύπου δε συμφέρει καθόλου ο FFT χωρίς ομαδοποίηση χρόνου. Αυτό σημαίνει δύο πράγματα. Πρώτον υπάρχει χώρος βελτίωσης για την υλοποίηση του FFT, αλλά δεύτερον και πιο σημαντικό, ότι η ομαδοποίηση βημάτων χρόνου είναι μία πολύ καλή και αποτελεσματική

μέθοδος επιτάχυνσης, τόσο για το επαναληπτικό όσο και για το πρότυπο στο πεδίο της συχνότητας.

6.2 Ποιότητα Κώδικα

Στο 3ο κέφαλαιο, μελετώντας δύο περιπτώσεις, έγινε αξιολόγηση της ποιότητας κώδικα των συναρτήσεων πυρήνων, γραμμένες σε Julia. Η εικόνα όμως δεν είναι ολοκληρωμένη καθώς ένα πρόγραμμα στοχευμένο για κάρτες γραφικών, πέρα από τη συνάρτηση πυρήνα, περιλαμβάνει κώδικα για τον έλεγχο και ρύθμιση παραμέτρων της κάρτας γραφικών, προεπεξεργασία και οπτικοποίηση δεδομένων, έλεγχο του αποτελέσματος, διεπαφή με το χρήστη κτλ. Η διαδικασία για τη δημιουργία της πλατφόρμας είχε ως αποτέλεσμα περισσότερη εμπάθυνση και καλύτερη κατανόηση των δυνατοτήτων αυτής της γλώσσας.

6.2.1 Δημιουργία της πλατφόρμας

Οι δυνατότητες μεταπρογραμματισμού και ενδοσκοπήσης ήταν σημαντικές, έως και απαραίτητες για την υλοποίηση ενός σχετικά πολύπλοκου προγράμματος, σε περιορισμένο χρόνο, από έναν μόνο προγραμματιστή. Χωρίς να συμπεριληφθούν οι αλγοριθμικές υλοποιήσεις για κάρτες γραφικών, τα πιο πολύπλοκα τμήματα του προγράμματος ήταν η μετατροπή του κώδικα που έδινε ως είσοδο ο χρήστης σε μαθηματικές πράξεις και αυτόματη παραγωγή κώδικα για κάρτες γραφικών από αυτές τις πράξεις. Το σύνθετο έργο της συντακτικής ανάλυσης κειμένου σε κώδικα και η μετατροπή κειμένου σε εκτελέσιμο κώδικα λύνονται αυτόματα από τη Julia. Έτσι μένει μόνο η υλοποίηση της λογικής.

Λόγω της εκφραστικότητας και ευελιξίας που παρέχει η Julia δε χρειάζεται να χρησιμοποιηθούν εξωτερικά προγράμματα ως συντακτικοί αναλυτές. Ο χρήστης δίνει ως είσοδο κώδικα Julia, που είναι αυτόματα σε μορφή δεδομένων κατανοητή για το πρόγραμμα.

Αξιοποιώντας, πάλι, τη δυνατότητα ενδοσκοπήσης, είναι δυνατόν να γραφτεί εύκολα κώδικας Julia μέσω της Julia. Στο παρακάτω δείγμα κώδικα είναι εμφανές πόσο απλό είναι να δημιουργηθεί κώδικας. Η μετατροπή του κώδικα από δομή δεδομένων σε εκτελέσιμη συνάρτηση γίνεται επίσης εύκολα μέσω βιβλιοθήκης.

Τμήμα Κώδικα 6.1: ά ή ώ Julia.

```
#Initialize code structure with 2 instructions
code = quote
    a = 0
    a += D[1]
end
#Add instruction to existing code structure
new_instruction = :(a += D[2])
push!(code, new_instruction)
```

Πολύ σημαντική επίσης είναι η δυνατότητα να οπτικοποιηθούν τα δεδομένα μέσα στο ίδιο το πρόγραμμα. Το γεγονός ότι δε χρησιμοποιείται άλλη γλώσσα προγραμματισμού, όπως συμβαίνει με τη C, κάνει την αποσφαλμάτωση πιο γρήγορη και εύκολη.

6.2.2 Μία Κάρτα Γραφικών

Τόσο στις δύο προηγούμενες μελέτες, όσο και στην πλατφόρμα για την απλή περίπτωση, υπάρχει έλεγχος μίας κάρτας γραφικών από τον επεξεργαστή. Ο έλεγχος περιλαμβάνει τον ορισμό μνήμης για την κάρτα, τη μεταφορά δεδομένων από και προς αυτή και την εκτέλεση της συνάρτησης πυρήνα. Οι χαμηλού επιπέδου [11] [10] συναρτήσεις της CUDA έχουν “τυλιχθεί” με κώδικα Julia και φαίνεται σαν να υποστηρίζεται έμφυτα από την γλώσσα ο προγραμματισμός μιας κάρτας γραφικών, αλλά και γενικά η εκτέλεση κώδικα σε αυτή.

Τμήμα Κώδικα 6.2: Παράδειγμα εκτέλεσης συνάρτησης-πυρήνα σε Julia.

```
# Upload data to GPU
device_data = CuArray(data)
# Execute GPU kernel
@cuda threads=32 blocks=(16,16) kernel(device_data)
```

Τμήμα Κώδικα 6.3: Παράδειγμα εκτέλεσης κώδικα σε κάρτα γραφικών χωρίς συνάρτηση πυρήνα σε Julia.

```
# Upload data to GPU
devA = CuArray(dataA)
devB = CuArray(dataB)
# Array multiplication in GPU
dev_result = devA*devB
# Download result to CPU
res = Array(dev_result)
```

Για την εκτέλεση συνάρτησης πυρήνα για πρότυπο, ήταν απαραίτητο να αλλάξει το μέγεθος του πίνακα και να γεμίσουν με μηδενικά οι καινούριες θέσεις. Στην C, για να υλοποιηθεί αυτό, θα απαιτούνταν η χρήση νέου πίνακα στη RAM και η μετακίνηση των στοιχείων σε αυτόν, που απαιτεί διπλάσια μνήμη. Λόγω του υψηλού επιπέδου της Julia, μπορεί πολύ εύκολα να δημιουργηθεί η περιγραφή του επαυξημένου πίνακα χωρίς να βρίσκεται πραγματικά στη μνήμη, και έπειτα μέσω της περιγραφής να γίνει η μεταφορά δεδομένων στην κάρτα γραφικών. Στο παρακάτω δείγμα κώδικα ορίζεται μια συνάρτηση που δημιουργεί επαυξημένο πίνακα προσθέτοντας *pd* στοιχεία σε 4 από τις 6 πλευρές του πίνακα. Έπειτα, η μετακίνηση των δεδομένων στην κάρτα γίνεται όπως και στα απλά δεδομένα.

Τμήμα Κώδικα 6.4: Δημιουργία επαυξημένου πίνακα σε Julia.

```
function PadData(pd, data)
    x = size(data,1)
    y = size(data,2)
    z = size(data,3)
    padx = 1:(x+2pd)
    pady = 1:(y+2pd)
    padz = 1:z
    datax = (pd+1):(x+pd)
    datay = (pd+1):(y+pd)
    dataz = (1:z)
```

```

return PaddedView(0, data,
                  (padx,pady,padz),
                  (datax, datay, dataz))

end
padded_data = PadData(data, pd)
dev_arr = CuArray(padded_data)

```

Μια τέτοια προσέγγιση θα μπορούσε να υλοποιηθεί στην C, όμως θα απαιτούσε κόπο, χρόνο και δε θα μπορούσε να καλύψει πολλές περιπτώσεις όπως γίνεται σε μια γλώσσα υψηλού επιπέδου.

6.2.3 Πολλαπλές κάρτες γραφικών

Μέχρι αυτήν τη στιγμή (Δεκέμβριος 2020), υποστηρίζει λίγες δυνατότητες από την εργαλειοθήκη της CUDA για προγραμματισμό σε πολλαπλές κάρτες γραφικών [28]. Η δουλειά για υποστήριξη πολλαπλών καρτών γραφικών είναι σε εξέλιξη. Το γεγονός αυτό έκανε αρκετά πιο δύσκολη την υλοποίηση για πολλαπλές κάρτες γραφικών από την πλατφόρμα.

Πολύ μεγάλο μέρος του χρόνου αναλώθηκε σε απλά πράγματα, όπως η δέσμευση ομογενοποιημένης μνήμης ή η μεταφορά τμήματος πίνακα από μία κάρτα γραφικών σε άλλη. Καμία από τις συναρτήσεις που χρειάστηκαν δεν υπήρχαν στο εγχειρίδιο της γλώσσας. Επίσης, η Julia δεν υποστηρίζει έμφυτα τη χρήση δεικτών μνήμης, η χρήση των συναρτήσεων CUDA σε Julia ήταν διαφορετική από ότι στην C.

Στο επόμενο παράδειγμα κώδικα, φαίνονται τα βήματα που χρειάζονται για να γίνει χρήση της ομογενοποιημένης μνήμης που παρέχει η CUDA. Ένα σημαντικό εμπόδιο, είναι πως αυτό το χαρακτηριστικό δεν υποστηρίζεται άμεσα από τη βιβλιοθήκη CuArrays, που διευκόλυνε σε πολύ μεγάλο βαθμό τη διαδικασία σε μία κάρτα γραφικών. Για να υπάρχει τρισδιάστατη διευθυνσιοδότηση όμως, πρέπει τα δεδομένα να δίνονται στην συνάρτηση πυρήνα ως CuArray. Έτσι, αρχικά δημιουργείται ένας ομογενοποιημένος ενδιάμεσος καταχωρητής buffer, μετατρέπεται σε δομή δεδομένων που παίζει το ρολό δείκτη και τέλος σε CuArray.

Τμήμα Κώδικα 6.5: Δέσμευση ομογενοποιημένης μνήμης με CUDA σε Julia.

```

gpu_buffer = Mem.alloc(Mem.Unified,
                      size(data)*sizeof(Float32))
gpu_pointer = convert(CuPtr{Nothing}, gpu_buffer)
gpu_cuarray = unsafe_wrap(CuArray{Float32, 3},
                          gpu_pointer, x, y, z,
                          own=false)

```

Κάθε μια από αυτές τις μεταβλητές χρησιμοποιείται μέσα στον κώδικα, ο ενδιάμεσος καταχωρητής για μεταφορά δεδομένων από επεξεργαστή προς κάρτες γραφικών, ο δείκτης για μεταφορά τμήματος μνήμης μεταξύ καρτών γραφικών και CuArray σαν όρισμα στις συναρτήσεις πυρήνα.

Η μεταφορά δεδομένων ανάμεσα σε κάρτες γραφικών είναι σχετικά απλή, μοιάζει με την C, όμως δεν αρμόζει σε κώδικα υψηλού επιπέδου όπως φαίνεται από το επόμενο

παράδειγμα :

Τμήμα Κώδικα 6.6: Αντιγραφή τμήμα μνήμης σε άλλο τμήμα μνήμης στις κάρτες γραφικών με Julia.

```
p1 = gpu_pointers_in[i[1]]  
p2 = gpu_pointers_in[i[2]]  
offp1 = p1 + dx*dy*(dz-2radius*t_group)*sizeof(Float32)  
CUDA.cuMemcpy(p2, offp1, bsize)
```

Αλλά σημαντικά προβλήματα που αντιμετωπίστηκαν ήταν η αποδέσμευση μνήμης και η πραγματική δέσμευση ομογενοποιημένης μνήμης. Η βιβλιοθήκη CuArrays ακολουθεί το μοντέλο της γλώσσας και έχει αυτόματη αποδέσμευση μνήμης για τις κάρτες γραφικών. Επειδή δεν υποστηρίζει ομογενοποιημένη μνήμη, όταν μετατρέπεται ο ενδιαμέσος καταχωρητής σε CuArray, η βιβλιοθήκη προσπαθεί να αποδεσμεύσει τη μνήμη, η οποία δεν της ανήκει. Αυτό οδηγεί σε σφάλματα που είναι δύσκολο να εντοπιστεί η πραγματική τους αιτία, καθώς συνέβαιναν σε τυχαίο χρόνο. Όσον αφορά την ομογενοποιημένη μνήμη, η Julia λανθασμένα δεσμεύει όλους τους πίνακες σε μία κάρτα γραφικών, πριν “καταλάβει” και δεσμεύσει κάθε πίνακα στη σωστή και έτσι, υπάρχει μια μικρή καθυστέρηση. Αυτό το πρόβλημα δεν εντοπίστηκε σε πρόγραμμα στη γλώσσα C.

Κεφάλαιο 7

Συμπεράσματα και Μελλοντική Έρευνα

Στην παρούσα διπλωματική έγινε ανάλυση δύο διαφορετικών θεμάτων: η καταλληλότητα μιας γλώσσας προγραμματισμού για κάρτες γραφικών και η δημιουργία πλατφόρμας αυτόματης παραγωγής κώδικα για επιτάχυνση υπολογισμών προτύπων. Η Julia, μια υψηλού επιπέδου και απόδοσης γλώσσα προγραμματισμού, γνωστή σε εφαρμογές υπολογισμών υψηλής απόδοσης, απέκτησε πρόσφατα υποστήριξη για προγραμματισμό σε κάρτες γραφικών. Η νεότητά της σε αυτόν τον τομέα, απαιτεί εκτενείς έρευνες για να γίνει πιο διαδεδομένη η χρήση της. Οι υπολογισμοί προτύπων, όπως έχει ήδη αναφερθεί, χρησιμοποιούνται σε πολλούς αλγόριθμους, οι οποίοι με την σειρά τους αξιοποιούνται σε πολλά διαφορετικά επιστημονικά πεδία. Έτσι, είναι απαραίτητη η επιτάχυνση και αυτοματοποίηση αυτών των υπολογισμών.

Τα δύο αυτά θέματα είναι στενά συνδεδεμένα. Η αξιολόγηση της γλώσσας έγινε σε πραγματικές συνθήκες έρευνας και όχι μόνο με αυτόνομες μετρήσεις για διάφορους αλγόριθμους. Η πολυπλοκότητα της πλατφόρμας, έδωσε την ώθηση να διερευνηθούν πολλά από τα χαρακτηριστικά της γλώσσας πέρα από την ταχύτητά της. Από την άλλη, για το κομμάτι της έρευνας για επιτάχυνση υπολογισμών προτύπων σε κάρτες γραφικών, αξιοποιώντας την παραγωγικότητα της Julia, έγινε έρευνα σε βάθος αλλά και σε εύρος. Μελετήθηκαν εκτενώς βελτιστοποιήσεις χαμηλού επιπέδου, τροποποιήσεις αλγορίθμων, αλλά και έγιναν υλοποιήσεις για πολλές κάρτες γραφικών, υπολογισμός προτύπων στη συχνότητα και αυτόματη παραγωγή κώδικα.

7.1 Συζήτηση για υπολογισμούς προτύπων

7.1.1 Συμπεράσματα

Οι υπολογισμοί προτύπων αποτελούν ένα ευρέως διαδεδομένο αντικείμενο που έχει διερευνηθεί σε βάθος για επιτάχυνση σε επεξεργαστές, κάρτες γραφικών και διανεμημένα συστήματα. Η συνεισφορά αυτής της διπλωματικής βρίσκεται κυρίως σε δύο βελτιστοποιήσεις.

Η διαφορετική προσέγγιση της ομαδοποίησης βημάτων χρόνου, έδωσε τη δυνατότητα επιπλέον επιτάχυνσης σε τρισδιάστατα πρότυπα, όπου η συμβατική ομαδοποίηση βημάτων χρόνου δε βελτίωνε την απόδοση. Η τεχνική αυτή μπορεί ακόμα να εφαρμοστεί

εύκολα σε μη-ολιστικές προσεγγίσεις και σε αυτόματη παραγωγή κώδικα. Η δεύτερη συνεισφορά είναι η εκτέλεση των υπολογισμών προτύπων στο πεδίο της συχνότητας μέσω FFT, συνδυάζοντας και την ομαδοποίηση βημάτων χρόνου. Η ομαδοποίηση είναι απαραίτητη, καθώς τα πρότυπα είναι αραιά, και δεν υπάρχει βελτίωση αν για ένα βήμα χρόνου κάνουμε ένα πέρασμα FFT, όπως στη συνέλιξη. Αξιοποιώντας την ομαδοποίηση, μπορούμε να εφαρμόσουμε ένα πέρασμα FFT, με λίγο μεγαλύτερη διάρκεια από πριν, αλλά με υπολογισμό πολλών βημάτων χρόνου.

Η πλατφόρμα που δημιουργήθηκε υποστηρίζει αυτόματη παραγωγή κώδικα για πολλαπλές κάρτες γραφικών. Για 2 κάρτες γραφικών, επιτεύχθηκε η μέγιστη επιτάχυνση ($\times 2$), ενώ για 4 η βελτίωση ήταν καλή, αλλά η επιτάχυνση δεν αυξήθηκε γραμμικά λόγω των επικοινωνιών μεταξύ των καρτών γραφικών. Ακόμα δοκιμάστηκε να γίνει συγχώνευση βημάτων χρόνου πριν την επικοινωνία των καρτών, όπως έχει προταθεί στη βιβλιογραφία, χωρίς όμως επιτυχία. Τέλος, οι μέθοδοι βελτιστοποίησης, εκτελέστηκαν και για δισδιάστατα πρότυπα με επιτυχία, παρόλο που η πλατφόρμα δημιουργήθηκε έχοντας κατά νου τα τρισδιάστατα πρότυπα.

7.1.2 Μελλοντική Έρευνα

Στην εργασία αυτή αναλύθηκε και υλοποιήθηκε η απλή εκδοχή του προτύπου. Δηλαδή, υπάρχει μόνο ένα πλέγμα δεδομένων και το πρότυπο χρησιμοποιεί μόνο τιμές του αμέσως προηγούμενου βήματος χρόνου. Πιο πολύπλοκες εκδοχές υπολογισμών προτύπων περιλαμβάνουν πολλαπλά πλέγματα, επιπλέον πίνακες με συντελεστές και χρήση πιο παλιών προηγούμενων τιμών. Γενικά, υπάρχουν έρευνες σε αυτό το κομμάτι, αλλά θα ήταν ενδιαφέρον να μελετηθεί πως η Julia μπορεί να χειριστεί πιο πολύπλοκα πρότυπα, τόσο σε επίπεδο επιτάχυνσης, όσο και σε επίπεδο αυτόματης παραγωγής κώδικα και διεπαφής με τον χρήστη. Επιπλέον, ο παραγόμενος κώδικας θα μπορούσε να είναι προσβάσιμος από τον προγραμματιστή, ο οποίος θα τον τροποποιεί και θα προσθέτει δικές του λειτουργίες. Τέλος, η υλοποίηση με FFT μπορεί να βελτιωθεί περαιτέρω και να εντοπιστούν πιο αυστηρά όρια, πέρα από τα οποία συμφέρει ο FFT από την επαναληπτική μέθοδο.

7.2 Συζήτηση για την Julia

7.2.1 Συμπεράσματα

Οι δυνατότητες της Julia, σε επίπεδο επεξεργαστή, ήταν παραπάνω από χρήσιμες. Η προεπεξεργασία δεδομένων έγινε ταχύτατα και με ελάχιστο κώδικα., όπως και η οπτικοποίηση δεδομένων, που ήταν απαραίτητη για την αποσφαλμάτωση του προγράμματος. Αξιοποιώντας τον μεταπρογραμματισμό δημιουργήθηκε, χωρίς υπερβολικό κόπο, πλατφόρμα αυτόματης παραγωγής κώδικα.

Όσον αφορά την ταχύτητα της Julia σε κάρτες γραφικών, τα αποτελέσματα συμπίπτουν με τις ήδη δημοσιευμένες μετρήσεις. Η Julia κινείται στα ίδια επίπεδα ταχύτητας με τη C. Αρκετές φορές, τόσο στις δύο μελέτες όσο και στην πλατφόρμα, ήταν σημαντικά γρηγορότερη. Σχετικά με την ποιότητα κώδικα, η Julia προφανώς υπερτερεί της C, ως γλώσσα υψηλού επιπέδου. Οι γνώσεις από την CUDA C μεταφέρονται εύκολα στην Julia. Η σύνταξη των συναρτήσεων πυρήνων ακολουθεί το ίδιο σκεπτικό (αφού εξαρτάται από το hardware) και είναι εμπλουτισμένη με υψηλού επιπέδου εντολές. Η διαχείριση

μίας κάρτας γραφικών φαίνεται σαν να υποστηρίζεται έμφυτα από τη γλώσσα. Αρκετά από τα υψηλού επιπέδου χαρακτηριστικά της γλώσσας, έχουν ενσωματωθεί στη βιβλιοθήκη CUDA.jl. Πολύ απλοί αλγόριθμοι μπορούν να εκτελεστούν στην κάρτα γραφικών εύκολα, ακόμα και χωρίς τη σύνταξη συναρτήσεων-πυρήνων. Για πολύπλοκους αλγόριθμους η διαδικασία είναι πιο εύκολη από ότι στην C αφού το υψηλό επίπεδο επιτρέπει τη σύνταξη κατανοητού και υψηλής ποιότητας κώδικα.

Υπάρχουν δύο τομείς στους οποίους η Julia δεν είναι τόσο κατάλληλη. Πρώτον, δεν υπάρχει καλή υποστήριξη για πολλαπλές κάρτες γραφικών. Απλά και εύκολα διασπάσιμα προβλήματα μπορούν να τρέξουν με Julia σε πολλαπλές κάρτες γραφικών χωρίς κόπο και προβλήματα. Όμως για πιο περίπλοκα προβλήματα, το πέπλο του υψηλού επιπέδου πέφτει και η υποστήριξη είναι περιορισμένη. Ο προγραμματιστής πρέπει να "πέσει" στο χαμηλό επίπεδο των εντολών CUDA C, οι οποίες είναι επιφανειακά "τυλιγμένες", αλλά πρέπει και να μελετήσει το χαμηλό επίπεδο της Julia για να μπορέσει να χρησιμοποιήσει δείκτες (που δεν υποστηρίζονται έμφυτα) και να αποφύγει σφάλματα κατά τη δέσμευση και την αποδέσμευση μνήμης. Έτσι, χάνεται η παραγωγικότητα, που είναι το δυνατό στοιχείο της γλώσσας και η C φαίνεται να είναι πιο σίγουρη και απλή λύση.

Ο δεύτερος τομέας, στον οποίο η Julia δεν είναι κατάλληλη, είναι οι εφαρμογές πραγματικού χρόνου. Παρόλο που δεν παρουσιάστηκε σε προηγούμενο κεφάλαιο, η πρώτη εκτέλεση μιας συνάρτησης πυρήνα απαιτεί αρκετό χρόνο (μερικά δευτερόλεπτα), καθώς τότε ενεργοποιείται το βήμα της μεταγλώττισης. Επίσης, μερικά δευτερόλεπτα διαρκεί και η εκκίνηση του οδηγού της CUDA για τις κάρτες γραφικών. Τέλος, η διαχείριση μνήμης γίνεται αυτόματα από τη βιβλιοθήκη. Ενώ είναι δυνατόν να γίνει και προγραμματιστικά, κάτι τέτοιο δεν είναι ο στόχος της βιβλιοθήκης. Αυτές οι περιπτώσεις καθιστούν την Julia ακατάλληλη για εφαρμογές ευαίσθητες στον χρόνο, όπως αλγόριθμοι μηχανικής όρασης σε αυτόνομο όχημα.

Καταλήγοντας, η Julia αποτελεί μια πάρα πολύ καλή επιλογή για προγράμματα που απαιτούν την επιτάχυνση που προσφέρουν οι κάρτες γραφικών. Ακόμα και για πραγματικού χρόνου εφαρμογές, η Julia είναι κατάλληλη για την ανάπτυξη πρότυπου και βελτιστοποίησή του, πριν μετατραπεί σε γλώσσα χαμηλού επιπέδου. Ερευνητικές εργασίες και μηχανικοί που ασχολούνται με την επιστήμη των δεδομένων, μπορούν να επωφεληθούν πολύ, τόσο από την παραγωγικότητα και απλότητα της γλώσσας, όσο και από ταχύτητα της Julia σε επεξεργαστές και κάρτες γραφικών.

7.2.2 Μελλοντική Έρευνα

Ένα πολύ σημαντικό εύρημα που προέκυψε κατά την διεκπεραίωση των δύο μελετών, είναι η διαφορετική συμπεριφορά της Julia από τη C για ίδιο πηγαίο κώδικα. Η Julia χρησιμοποιεί περισσότερους καταχωρητές και διαφέρει σε κάποιες χαμηλότερου επιπέδου μετρικές. Ένα ενδιαφέρον θέμα έρευνας θα ήταν να εξηγηθεί αυτή η συμπεριφορά και να βρεθεί τρόπος να αξιοποιηθεί όταν η Julia είναι πιο γρήγορη, ή να διορθωθεί όταν είναι πιο αργή. Ακόμα, υπάρχει η απορία, πώς εντολές υψηλού επιπέδου, που δεν αλλάζουν τον αλγόριθμο, βελτιώνουν την ταχύτητα. Παρόμοια έρευνα μπορεί να γίνει για τις υψηλού επιπέδου εντολές που χρησιμοποιούνται στις συναρτήσεις-πυρήνες και για τη μη-δήλωση τύπων στις μεταβλητές. Τα δύο αυτά υψηλού επιπέδου χαρακτηριστικά είχαν ως αποτέλεσμα τη βελτίωση της απόδοσης χωρίς να αλλάζουν την αλγοριθμική προσέγγιση. Η ανάλυση της εσωτερικής τους λειτουργίας

γίας θα μπορούσε να δώσει χρήσιμες πληροφορίες για την βελτιστοποίηση κώδικα για κάρτες γραφικών.

Κεφάλαιο 8

Παράρτημα

Τμήμα Κώδικα 8.1: Julia παράδειγμα παραγόμενου κώδικα για τρισδιάστατο πρότυπο-αστέρι με ακτίνα 2.

quote

```
dimz = size(g_input, 3)
dimzend = dimz - 2
bdimx = ((CUDA).blockDim()).x
bdimy = ((CUDA).blockDim()).y
bx = (((CUDA).blockIdx()).x - 1) * 32 + 1 + offx
by = (((CUDA).blockIdx()).y - 1) * 32 + 1 + offy
tx = ((CUDA).threadIdx()).x
ty = ((CUDA).threadIdx()).y
txr = ((CUDA).threadIdx()).x + 2
tyr = ((CUDA).threadIdx()).y + 2
tile = (CUDA).@cuDynamicSharedMem(Float32, (36, 36))
@inbounds l_input = @view(g_input[bx:bx + 35,
                                   by:by + 35, :])
@inbounds l_output = @view(g_output[bx:bx + 35,
                                     by:by + 35, :])

behind2 = Float32(0.0)
behind1 = Float32(0.0)
current = Float32(0.0)
infront1 = Float32(0.0)
infront2 = Float32(0.0)
cfarr = (StaticArrays).SA_F32[0.25f0, 0.5f0]
for z = 1 + offz_f:dimz - offz_b
    (CUDA).sync_threads()
    if tx + 0 <= 36 && ty + 0 <= 36
        @inbounds tile[tx + 0, ty + 0] =
            l_input[tx + 0, ty + 0, z]
    end
    if tx + 0 <= 36 && ty + 32 <= 36
        @inbounds tile[tx + 0, ty + 32] =
            l_input[tx + 0, ty + 32, z]
```



```

end
if tx + 32 <= 36 && ty + 0 <= 36
    @inbounds tile[tx + 32, ty + 0] =
        l_input[tx + 32, ty + 0, z]
end
if tx + 32 <= 36 && ty + 32 <= 36
    @inbounds tile[tx + 32, ty + 32] =
        l_input[tx + 32, ty + 32, z]
end
(CUDA).sync_threads()
@inbounds temp = tile[txr + -2, tyr + 0]
current += cfarr[1] * temp
@inbounds temp = tile[txr + -1, tyr + 0]
current += cfarr[2] * temp
@inbounds temp = tile[txr + 0, tyr + -2]
current += cfarr[1] * temp
@inbounds temp = tile[txr + 0, tyr + -1]
current += cfarr[2] * temp
@inbounds temp = tile[txr + 0, tyr + 0]
current += temp
infront2 += cfarr[1] * temp
infront1 += cfarr[2] * temp
behind2 += cfarr[1] * temp
behind1 += cfarr[2] * temp
@inbounds temp = tile[txr + 0, tyr + 1]
current += cfarr[2] * temp
@inbounds temp = tile[txr + 0, tyr + 2]
current += cfarr[1] * temp
@inbounds temp = tile[txr + 1, tyr + 0]
current += cfarr[2] * temp
@inbounds temp = tile[txr + 2, tyr + 0]
current += cfarr[1] * temp
if z > 2
    @inbounds l_output[txr, tyr, z - 2] = behind2
end
behind2 = behind1
behind1 = current
current = infront1
infront1 = infront2
infront2 = Float32(0)
end
@inbounds l_output[txr, tyr, (dimz-0) - offz_b] = behind1
@inbounds l_output[txr, tyr, (dimz-1) - offz_b] = behind2
return nothing
end

```

Τμήμα Κώδικα 8.2: Julia. Απλή εκδοχή συνάρτησης πυρήνα για εύρεση κοντινότερων γειτόνων.

```
function cuGridKnnKernel(devPoints, devQueries,
    Pointsperblock, Queriesperblock,
    IntPointsperblock, IntQueriesperblock,
    devDistances, devNeighbours,
    dimensions, grids, offset)

if CheckBlockBounds(offset, blockIdx(), grids)
    return nothing
end

q_bid = ((blockIdx().z - 1)*gridDim().y*gridDim().x
        + (blockIdx().y - 1)*gridDim().x
        + blockIdx().x)
p_bid = ((blockIdx().z+offset.z-1)*gridDim().y*gridDim().x
        + (blockIdx().y + offset.y - 1)*gridDim().x
        + blockIdx().x + offset.x)
tid = threadIdx().x + (threadIdx().y-1)*blockDim().x
stride = (blockDim().x)*(blockDim().y)

SharedPoints = @cuDynamicSharedMem(Float32,
                                   (dimensions, stride))
SharedQueries = @cuDynamicSharedMem(Float32,
                                   (dimensions, stride),
                                   dimensions*stride*sizeof(Float32))

@inbounds startPoints = IntPointsperblock[p_bid]
@inbounds startQueries = IntQueriesperblock[q_bid]
@inbounds totalPoints = Pointsperblock[p_bid]
@inbounds totalQueries = Queriesperblock[q_bid]
@inbounds Points = @view devPoints[(startPoints+1):
                                   (startPoints+totalPoints), :]
@inbounds Queries = @view devQueries[(startQueries+1):
                                   (startQueries+totalQueries), :]
@inbounds Distances = @view devDistances[(startQueries+1):
                                   (startQueries+totalQueries)]
@inbounds Neighbours = @view devNeighbours[(startQueries+1):
                                   (startQueries+totalQueries)]
@inbounds query = @view SharedQueries[:, tid]
dist = Float32(0)
nb = Int32(0)
for q in 0:stride:(totalQueries-1)
    if tid + q <= totalQueries
        for d = 1:dimensions
            @inbounds query[d] = Queries[tid+q, d]
        end
        @inbounds dist = Distances[tid+q]
        @inbounds nb = Neighbours[tid+q]
    end
end
```

```

end
for p in 0:stride:(totalPoints-1)

    CUDA.sync_threads()
    if tid + p <= totalPoints
        for d in 1:dimensions
            @inbounds SharedPoints[d, tid]
                = Points[tid+p, d]

        end
    end
    CUDA.sync_threads()
    bounds::Int32 = CUDA.min(stride, totalPoints-p)
    for i in 1:bounds
        @inbounds point =
            @view SharedPoints[:, (i+tid-2)%bounds+1]
        tempdist = CalcDistance(query, point)
        if tempdist < dist
            dist = tempdist
            nb = Int32(startPoints+p+(i+tid-2)%bounds+1)
        end
    end
end
if tid + q <= totalQueries
    @inbounds Distances[tid+q] = dist
    @inbounds Neighbours[tid+q] = nb
end
end
return nothing
end

```

Βιβλιογραφία

- [1] J. Meng and K. Skadron, “A Performance Study for Iterative Stencil Loops on GPUs with Ghost Zone Optimizations,” *International Journal of Parallel Programming*, vol. 39, no. 1, pp. 115–142, Feb. 2011. [Online]. Available: <http://link.springer.com/10.1007/s10766-010-0142-5>
- [2] J. Holewinski, L.-N. Pouchet, and P. Sadayappan, “High-performance code generation for stencil computations on GPU architectures,” in *Proceedings of the 26th ACM international conference on Supercomputing*, ser. ICS '12. Association for Computing Machinery, pp. 311–320. [Online]. Available: <https://doi.org/10.1145/2304576.2304619>
- [3] M. Misic, Đurđević, and M. Tomasevic, “Evolution and trends in GPU computing,” Jan. 2012, pp. 289–294.
- [4] S. Che, M. Boyer, J. Meng, D. Tarjan, J. W. Sheaffer, S.-H. Lee, and K. Skadron, “Rodinia: A Benchmark Suite for Heterogeneous Computing,” p. 11.
- [5] P. Zunitich, “CUDA vs. OpenCL vs. OpenGL,” Jan. 2018, section: Editing. [Online]. Available: <https://www.videomaker.com/article/c15/19313-cuda-vs-opencl-vs-opengl>
- [6] J. L. Hennessy and D. A. Patterson, *Computer organization and design : the hardware/software interface*. San Francisco, Calif. : Morgan Kaufmann Publishers, 1998. [Online]. Available: <http://archive.org/details/computerorganiz000henn>
- [7] F. Fleutot and L. Tratt, “Contrasting compile-time meta-programming in Met-*alua* and *Converge*,” p. 10.
- [8] J. Bezanson, A. Edelman, S. Karpinski, and V. B. Shah, “Julia: A Fresh Approach to Numerical Computing,” *SIAM Review*, vol. 59, no. 1, pp. 65–98, Jan. 2017, publisher: Society for Industrial and Applied Mathematics. [Online]. Available: <https://epubs.siam.org/doi/10.1137/141000671>
- [9] C. Lattner and V. Adve, “LLVM: A Compilation Framework for Lifelong Program Analysis & Transformation,” in *Proceedings of the international symposium on Code generation and optimization: feedback-directed and runtime optimization*, ser. CGO '04. USA: IEEE Computer Society, Mar. 2004, p. 75.
- [10] T. Besard, C. Foket, and B. De Sutter, “Effective extensible programming: Unleashing Julia on GPUs,” *IEEE Transactions on Parallel and Distributed Systems*, 2018.

- [11] T. Besard, V. Churavy, A. Edelman, and B. De Sutter, "Rapid software prototyping for heterogeneous and distributed platforms," *Advances in Engineering Software*, vol. 132, pp. 29–46, 2019.
- [12] "CUDA C Best Practices Guide," p. 85.
- [13] K. Datta, M. Murphy, V. Volkov, S. Williams, J. Carter, L. Oliker, D. Patterson, J. Shalf, and K. Yelick, "Stencil computation optimization and auto-tuning on state-of-the-art multicore architectures," in *2008 SC - International Conference for High Performance Computing, Networking, Storage and Analysis*. Austin, TX: IEEE, Nov. 2008, pp. 1–12. [Online]. Available: <http://ieeexplore.ieee.org/document/5222004/>
- [14] P. Micikevicius, "3d finite difference computation on GPUs using CUDA," in *Proceedings of 2nd Workshop on General Purpose Processing on Graphics Processing Units - GPGPU-2*. ACM Press, pp. 79–84. [Online]. Available: <http://portal.acm.org/citation.cfm?doid=1513895.1513905>
- [15] T. Mo and L. Renfa, "A new memory mapping mechanism for gpgpus' stencil computation," *Computing*, vol. 97, pp. 795–812, 11 2014.
- [16] M. Frigo and V. Strumpen, "Cache oblivious stencil computations," *Proceedings of the 19th annual international conference on Supercomputing - ICS '05*. [Online]. Available: https://www.academia.edu/19784992/Cache_oblivious_stencil_computations
- [17] A. Nguyen, N. Satish, J. Chhugani, C. Kim, and P. Dubey, "3.5-d blocking optimization for stencil computations on modern cpus and gpus," 11 2010, pp. 1–13.
- [18] R. V. Lim, B. Norris, and A. D. Malony, "Autotuning GPU Kernels via Static and Predictive Analysis," *arXiv:1701.08547 [cs]*, Jun. 2017, arXiv: 1701.08547. [Online]. Available: <http://arxiv.org/abs/1701.08547>
- [19] S. Kamil, C. Chan, L. Oliker, J. Shalf, and S. Williams, "An auto-tuning framework for parallel multicore stencil computations," 04 2010, pp. 1–12.
- [20] J. D. Garvey and T. S. Abdelrahman, "A Strategy for Automatic Performance Tuning of Stencil Computations on GPUs," *Scientific Programming*, vol. 2018, pp. 1–24, May 2018. [Online]. Available: <https://www.hindawi.com/journals/sp/2018/6093054/>
- [21] A. Schäfer and D. Fey, "LibGeoDecomp: A Grid-Enabled Library for Geometric Decomposition Codes," Jan. 1970, pp. 285–294.
- [22] M. Christen, O. Schenk, and H. Burkhardt, "Patus: A code generation and autotuning framework for parallel iterative stencil computations on modern microarchitectures," 05 2011, pp. 676–687.
- [23] G. S. Murthy, M. Ravishankar, M. M. Baskaran, and P. Sadayappan, "Optimal loop unrolling for GPGPU programs," in *2010 IEEE International Symposium on Parallel & Distributed Processing (IPDPS)*. Atlanta, GA, USA: IEEE, 2010, pp. 1–11. [Online]. Available: <http://ieeexplore.ieee.org/document/5470423/>

- [24] R. A. Haddad and A. N. Akansu, "A class of fast Gaussian binomial filters for speech and image processing," *IEEE Transactions on Signal Processing*, vol. 39, no. 3, pp. 723–727, Mar. 1991, conference Name: IEEE Transactions on Signal Processing.
- [25] G. Papamakarios, G. Rizo, and N. Pitsianis, "FLCC: A library for fast computation of convolution and local correlation coefficients," 12 2011. [Online]. Available: <http://flcc.cs.duke.edu/home>
- [26] Παπαμακάριος, Γεώργιος και Ρίζος, Γεώργιος, "FLCC:ΜΙΑ ΒΙΒΛΙΟΘΗΚΗ ΓΙΑ ΤΑΧΥ ΥΠΟΛΟΓΙΣΜΟ ΣΥΝΕΛΙΞΗΣ ΚΑΙ ΤΟΠΙΚΩΝ ΣΥΝΤΕΛΕΣΤΩΝ ΣΥΣΧΕΤΙΣΗΣ," Διπλωματική Διατριβή, Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών, 2011, p. 159.
- [27] G. Martin, "The fantastic combinations of john conway's new solitaire game "life",," *Scientific American*, vol. 223, pp. 120–123, 1970.
- [28] "Multiple GPUs · CUDA.jl." [Online]. Available: <https://juliagpu.gitlab.io/CUDA.jl/usage/multigpu/>